

电子科技大学
UNIVERSITY OF ELECTRONIC SCIENCE AND TECHNOLOGY OF
CHINA

硕士学位论文

MASTER THESIS



论文题目 多目标检测前跟踪的粒子滤波算法研究

学科专业 信号与信息处理

学 号 201621020403

作者姓名 田真

指导教师 易伟 副教授

分类号 _____

密级 _____

UDC ^{注 1} _____

学 位 论 文

多目标检测前跟踪的粒子滤波算法研究

(题名和副题名)

田真

(作者姓名)

指导教师

易伟

副 教 授

电子科技大学

成 都

(姓名、职称、单位名称)

申请学位级别

硕士

学科专业

信号与信息处理

提交论文日期

2019.5

论文答辩日期

2019.5.29

学位授予单位和日期

电子科技大学

2019 年 6 月

答辩委员会主席

评阅人

注 1：注明《国际十进分类法 UDC》的类号。

Research on Multi-target Track-before-detect Method Based on Particle Filter Algorithm

A Master Thesis Submitted to

University of Electronic Science and Technology of China

Discipline: **Signal and Information Processing**

Author: **Zhen Tian**

Supervisor: **Wei Yi**

School: **School of Information and Communication**

Engineering

独创性声明

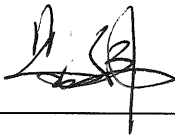
本人声明所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。据我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得电子科技大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

作者签名： 田 真 日期： 2019 年 5 月 28 日

论文使用授权

本学位论文作者完全了解电子科技大学有关保留、使用学位论文的规定，有权保留并向国家有关部门或机构送交论文的复印件和磁盘，允许论文被查阅和借阅。本人授权电子科技大学可以将学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。

（保密的学位论文在解密后应遵守此规定）

作者签名： 田 真 导师签名： 

日期： 2019 年 5 月 28 日

摘 要

在复杂探测环境中对多目标的检测跟踪是现代探测领域一项重要的共性基础研究，在国防领域具有重要意义。相对于传统的检测后跟踪（Detect before track, DBT）技术，新近提出的检测前跟踪（Track before detect, TBD）技术更为有效。大量研究表明，基于粒子滤波（Particle filter, PF）算法的 TBD 技术对弱小目标检测效果显著，但现阶段在理论、方法以及工程实践等方面仍存在不少亟待解决的问题。例如：多目标维数灾难、临近目标干扰、采样粒子数规模的合理设定等。

本文主要研究用于多目标 PF-TBD 算法，主要工作如下：

1、针对多目标跟踪的维数灾难问题，研究了独立分区交叉采样技术，并以此为基础，推导了独立分区粒子滤波算法，该算法利用后验独立假设，将高维度的多目标联合采样降维成为多个单目标采样，通过子分区交叉采样提高了粒子效率，从而使得计算量与目标数线性相关。

2、针对独立分区算法没有考虑目标临近干扰的问题，提出了基于并行分区状态采样的粒子滤波改进算法，在保持其后验独立假设的前提下，改进一阶权重的计算方法，将临近目标的影响纳入似然函数，从而提高了目标相互临近时的跟踪精度。

3、针对粒子滤波预设固定粒子数的问题，研究了一种基于 KL 距离（Kullback-Leibler distance, KLD）采样的自适应设定样本规模的采样方法，将其推广到多目标场景下，提出了基于 KLD 的动态粒子数并行分区粒子滤波算法。该算法以后验估计精度为依据，通过先验概率和后验概率分布的差异大小自适应地决定粒子数规模，在预设跟踪精度下使用尽可能少的粒子数，达到了减少计算量的目的。

4、针对无源声呐多目标 TBD 问题，研究了多目标 PF-TBD 的工程实现方案，利用多目标 PF-TBD 算法对两批某型无源声呐实测数据进行了离线处理，并对处理结果进行性能分析，验证了本文提出的 KLD-PP-PF 的 TBD 算法的有效性。

关键词：贝叶斯估计，非线性滤波，粒子滤波，多目标检测前跟踪

ABSTRACT

Multi-target tracking and detection in complex environment is an important research topic in modern detection systems as well as in the fields of national defense. Compared with traditional Detect-Before-Track (Detect before track, DBT), the newly proposed Track-before-detect (Track before detect, TBD) method is more efficient. Many studies have shown that TBD based on particle filter is of exceptional potency. Yet, there still exist many problems to be tackled in the field, for example, the curse of dimensionality, the interference of nearby targets and the reasonable setting of particle number, etc.

This thesis mainly focuses on the problems of multi-target particle filter TBD algorithms as follows:

1. To tackle the curse of dimensionality, the independent partitioned cross-sampling technique is studied, based on which an independent partition particle filter (IP-PF) is proposed. The IP method reduces the dimensions of multi-target states and improves the sampling efficiency with subparticle crossover. The IP method succeeds in making the computational complexity of multi-target tracking linearly related to the target number.

2. For the nearby-target interference problem that IP-PF cannot solve, the parallel partition (PP) state-sampling PF algorithm is proposed to ameliorate the situation. While retaining the posterior independence assumption of IP method and sampling conditional on estimated states, the multi-target likelihood is inserted into the computation of the first-stage weights so that the neighboring targets is properly taken into account.

3. To reduce the computational burden, a particle filter with an adaptive sample-size is proposed to sample based on KL distance inference and further generalized into multi-target scenario, which adaptively determines the sample size by measuring the difference between the prior probability and the posterior probability distribution.

4. The engineering implementation of multi-target particle filter TBD is finally studied to solve detection and tracking problem of passive sonar. The proposed PF-TBD algorithm is used to process two batches of offline sonar data. The performance analysis verifies the effectiveness of the proposed TBD algorithm.

Keywords: Bayesian estimation, nonlinear filtering, particle filter, track-before-detect

目 录

第一章 绪论	1
1.1 研究背景与研究意义	1
1.2 国内外研究动态	4
1.3 本文主要工作	6
第二章 多目标粒子滤波检测前跟踪算法	8
2.1 状态空间模型与贝叶斯推理框架	8
2.2 粒子滤波算法的基础理论	11
2.2.1 序贯重要性采样	11
2.2.2 粒子退化与重采样	13
2.2.3 使用粒子估计目标状态的实现	15
2.2.4 单目标 SIR-TBD 算法	15
2.2.5 辅助粒子滤波	16
2.3 多目标跟踪的联合多目标概率密度模型	19
2.3.1 多目标检测跟踪的贝叶斯推理建模	19
2.3.2 多目标系统模型与量测模型	21
2.4 算法仿真与性能分析	23
2.5 本章小结	28
第三章 基于并行分区状态采样的多目标 PF-TBD 改进算法	29
3.1 典型多目标粒子滤波算法	29
3.1.1 维数灾难问题	29
3.1.2 独立分区交叉采样	31
3.1.3 临近目标干扰问题	32
3.2 并行分区状态采样粒子滤波改进算法	33
3.3 算法仿真与性能分析	36
3.4 本章小结	45
第四章 基于 KL 距离的自适应粒子数多目标 PF-TBD 算法	46
4.1 基于 KL 距离的粒子数自适应设定	46
4.1.1 KL 距离基本理论	46
4.1.2 引入 KL 距离估计后验估计精度	47
4.1.3 基于 KL 距离变粒子数采样的 PP-PF 算法设计与流程	49

4.2 算法仿真与性能分析	52
4.3 本章小结	60
第五章 无源声呐水声目标 PF-TBD 处理方案及性能验证	61
5.1 无源声呐水声目标的 PF-TBD 处理方案	61
5.1.1 无源声呐系统接收信号模型	61
5.1.2 接收信号的波束形成方法与方位历程图	64
5.1.3 无源声呐水声目标的系统模型和量测模型	64
5.1.4 方位历程图的背景均衡处理	65
5.1.5 目标航迹起始与终止	67
5.2 无源声呐水声目标 PF-TBD 算法实测数据处理	69
5.2.1 第一批实测数据处理	70
5.2.2 第二批实测数据处理	72
5.3 本章小结	75
第六章 结束语	76
6.1 全文总结	76
6.2 工作展望	77
致 谢	78
参考文献	79
攻读硕士学位期间取得的科研成果	83

第一章 绪论

无论是在现代军事领域还是民用领域，目标检测与跟踪技术均具有出非常突出的应用价值，也是近年来研究的热点^[1]。在军事领域中，空间与海上预警、武器制导、飞行与舰船器导航系统等广泛采用了目标的检测和跟踪技术；而目标的小型化、隐身化、高速化发展和探测环境的多样化，给现代探测系统带来了愈发严峻的挑战。

1.1 研究背景与研究意义

在以现代电子战为代表的现代高水平科技战争中，为了给指挥控制系统的预留更富余的响应时间，要求探测系统在远距离处就可以快速地检测到目标。如果能够尽早发现、跟踪和锁定目标，就可以十分高效地指挥武器系统采取攻防策略、拦截或防卫响应。然而，在诸如隐身飞机、巡航导弹等低可观测目标的监视处理中，由于被传感器探测到的目标的信噪比（Signal-to-noise ratio, SNR）低，使得发现目标比较困难^[2]。如低 RCS 的隐身目标和远程预警等。总结来说，当前面临的主要挑战是在强杂波背景下对信噪比较低的目标进行检测。在实际工程中的强杂波主要指接收到的除雷达感兴趣的探测目标以外的其他散射强回波。比如，对于雷达系统而言，其感兴趣的探测物体主要是军事目标如导弹、飞机等，而对于一些干扰较强的回波如地面建筑物、云层及海情复杂的地区所特有的气象等即为需要处理和进一步分析的强杂波。一般地，在海杂波情况下，在距雷达 200 公里范围外，信杂比（Signal-to-scatter ratio, SCR）往往只有 7-9dB。这些由于自身尺寸小、采取了隐身措施或是距离较远、所处环境复杂而难以探测的目标通常被称为微弱目标。

一般而言，解决弱目标的探测问题主要集中在对硬件设施的改进上，如增强检测系统的前端以及接收设备的灵敏度等，具体措施包括增大雷达天线的发射功率，提升天线的增益或者减小接收机的噪声系数。另一方面，对于微弱目标的探测和跟踪能力的提高还可以通过算法层面如信号处理部分等加以改善。

对目标进行检测与跟踪的传统处理方法是先检测后跟踪（Detect before track, DBT）方法。该算法的核心思想是首先通过信号级处理方法如运动目标指示和运动目标检测等对目标能量进行帧内积累，并且设置第一检测门限对噪声进行滤除，以得到潜在的目标点迹信息。之后，在联合多帧数据间目标的运动特性，对存在关联性的目标点迹进行融合最后滤波输出目标跟踪轨迹。在过去的数十年间，DBT 技术已经在雷达的各个领域取得了全面的应用型进展。

图 1-1 所示为 DBT 处理流程示意图。




图 1-1 DBT 处理流程示意图

采用传统的跟踪前检测算法具有两大优势。第一，由于原始量测平面已经进行了第一门限检测，因此大量的噪声以及类噪声量测将被滤除，保留下来的量测信息大大减少，计算量大幅降低。第二，该算法中的跟踪阶段只需要对当前时刻过门限的点迹进行关联和滤波处理，而不需要保留以往的历史数据，且目标的幅度信息不被保留，只存储点迹信息的位置信息，因此数据量进一步得到了降低。虽然该算法能够有效降低雷达系统所需要的计算量和数据存储空间，但是当面临强杂波背景下的微弱目标检测问题时，算法性能受到严重影响，无法有效检测和跟踪出低信噪比目标，因此仍存在大量问题。传统的检测跟踪处理结构也面临着目标信息的丢失与点迹关联两大问题。尤其是在弱目标跟踪场景中，门限处理很容易导致能量较弱目标的漏检问题，这主要是由于 DBT 算法对于接收到的每一帧量测都设置了检测门限，并且在门限判决后，将超过门限的点迹信息保留下来，而未超过检测门限的点迹将被丢弃；由于微弱目标的信噪比较低，能量较弱，因此在进行单帧门限检测时，目标极有可能被滤除，从而使得在该算法的跟踪阶段无法对目标点迹进行有效的跟踪；而对于该环境中的强杂波而言，其幅度值由于较高而更有可能被保留下来用于后期的跟踪，因此同样会造成目标的错误检测。此外，在多帧关联时，如果过门限的点迹过多，那么点迹关联的难度将会非常大，并且容易出现虚假航迹以及消耗大量的系统资源。

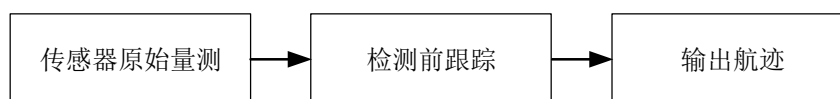


图 1-2 TBD 技术流程示意图

对比于传统 DBT 流程，通常将流程如图 1-2 检测前跟踪（Track before detect, TBD）技术定位为介于信号处理和数据处理之间的方法，对于该算法而言，第一检测门限的设置是不必要的，因为该算法更倾向于保留原始量测的所有信息（即包括潜在目标的量测），通过增加时间这一维度（即帧数）来对微弱目标的能量进行帧

间的信噪比积累，从而达到对微弱目标的检测；具体而言，该算法在目标积累阶段利用了目标帧间的运动学特性来对微弱目标与噪声进行区分，由于噪声在帧间的运动是弱相关而目标为强相关，因此目标的能量通过帧间积累能够有效地被利用起来而噪声则不会，从而实现对微弱目标的跟踪。

TBD 技术与 DBT 技术不同在于：

(1) 它对单帧数据不进行门限处理（或者设置远远低于 DBT 技术所采用的的门限）；此外，由于未设置单帧检测门限，TBD 技术还很好地保留下来了原始的量测信息，包括所有点迹的位置以及幅度信息。

(2) TBD 算法通过对原始量测进行联合的多帧处理，将微弱目标沿着目标运动特征进行有效积累，在多帧处理之后对值函数进行门限判决，最后输出航迹的检测结果，而不同于 DBT 算法在每一帧都输出当前的跟踪结果。

对于 DBT 算法而言，由于 TBD 算法并未对原始量测进行任何的修正，因此它能够确保对微弱目标信息的有效保留，而不会如 DBT 算法一样由于第一检测门限的设置而丢失微弱目标的信息。这对强杂波背景下的微弱目标的检测与跟踪问题十分有利，因为与此同时，TBD 算法还联合了多帧的量测信息对目标能量进行积累，充分利用了目标的运动学特性对无关强杂波进行了有效抑制。所以，相对于传统的 DBT 算法而言，TBD 算法对杂波的抑制能力更为出色，并且能够更大程度的减少虚假航迹现象，有效改善了低信噪比强杂波背景下的目标检测和跟踪性能。

目前 TBD 研究领域主要存在的几种主流的实现方法是：三维匹配滤波^[4]、多级假设检验算法^[5]、霍夫变换（Hough transform, HF）TBD 算法^[6]、动态规划 TBD 算法^[7-8]、粒子滤波 TBD 算法等。以上实现方法主要可以分成两种类别：第一类称作批处理的实现方法，如动态规划、霍夫变换等；第二类称为递归迭代的处理方式，主要有如粒子滤波算法。

粒子滤波算法是一种基于贝叶斯推理，采用蒙特卡洛迭代方式实现的方法。该算法的核心思想是对目标状态空间中随机分布一批有权重的粒子来对目标的后验概率密度进行拟合。粒子滤波算法相对于批处理的实现方式而言，所需要存储的数据量大大降低，并且对于存储量和计算量的需求都比较少。

倘若不对粒子滤波技术进行任何改进，直接将其应用到 TBD 上，确实能够带来许多的优势，但同时也存在一些亟待解决的问题。在单目标的跟踪场景下，检测跟踪类算法只需要对所扫描区域内做出有无目标的判决即可，并且在判决为真的条件下输出目标的跟踪航迹；而对于多目标的跟踪场景，则需要算法能够同时对多帧的量测信息进行估计和预测当前区域潜在的目标个数以及状态，这就极大地增加了跟踪的难度。对于多目标的粒子滤波跟踪算法而言，必须保持两种特性，分别

是能够准确地对新生目标进行航迹起始，以及能够一直对目标实现跟踪直至目标量测信息消失，也就是说该算法能够适应目标个数持续变化的场景。此外，在多目标的跟踪场景下，当出现了临近目标时，往往会造成算法性能的损失。这是由于当场景内存在临近目标时，若其中一个目标的信噪比较高，即能量较强，则会掩盖另一个弱目标，也会造成跟踪阶段的目标航迹丢失。粒子滤波算法有多种选择方式，虽然对于每种选择方式下粒子数目的选择准则也不尽相同，但是对于该算法而言，所采用的的粒子数越多，则跟踪性能越好，但相应地计算量也会越大，这就对在实际工程中实现粒子滤波算法的实时性带来了巨大的挑战。大部分的粒子滤波算法用一个固定的粒子数经验值进行采样，但在实际工程应用中，需要很好地平衡所需计算消耗与跟踪准确性之间的关系，做出取舍。

1.2 国内外研究动态

传统上，粒子滤波算法领域的早期的研究工作可以追溯到 Gordon 和 Salmond 等人在 1993 年对于非线性、非高斯模型下贝叶斯状态估计方法的研究，他们将其命名为自举滤波器^[10]。在 1999 年，粒子滤波这一术语被 Carpenter 等人正式使用^[11]。在 2001 年 Gordon 和 Salmond 为了缓解序贯重要性采样算法的粒子退化问题，在算法中增加了重采样步骤，从而第一次正式提出序贯重要性重采样算法^[12]。Salmond 等人对目标状态矢量进行了扩展，添加了一个描述目标存在性的二元变量，使粒子可以新生和消失，通过存在性变量和粒子状态信息联合估计目标状态，同时可以利用当前时刻的存活粒子数占比近似得到目标存在概率^[13]。2004 年，Rutten 等人以 Salmond 方法为基础，提出了一种优效的 PF-TBD 算法，该算法将所有粒子被分成和继续存在两类，采用两种粒子混合滤波去估计目标出现的概率以及目标的状态；该算法相比 Salmond 算法提高了样本使用效率，在实现同等跟踪性能条件下减少了粒子规模，降低了算法计算量^[14-15]，该算法在随后在 Swelling 目标起伏模型下的弱目标 TBD 场景下得到了进一步应用^[16]。

在众多粒子滤波算法中，粒子数是影响滤波器估计性能的一个重要参数，也和蒙特卡洛算法的计算量密切相关。然而，上述大部分粒子滤波算法研究均使用固定的粒子数目，研究者往往根据经验值设定一个足够大的样本规模。如何使预设粒子数更合理，并在满足某种精度要求的条件下使用尽可能少的粒子即成为粒子滤波算法研究中一个要点^[17-18]。1999 年，卡耐基梅隆大学的 D.Fox 提出了一种基于对数似然比的动态粒子数算法，并在移动机器人定位的应用场景中表现了优于固定粒子数 PF 算法的性能。该算法通过衡量重要性密度分布和目标真实分布的匹配程度来决定粒子数^[19-21]，然而该匹配度并非在所有情况下都能对采样所需粒子数的

进行精确估计，并未挖掘出动态粒子数算法的全部潜力。2004 年捷克西波西米亚大学的 Straka 和 Simandl 等人以样本分布质量为依据提出了另一种基于当前量测似然值检测的自适应粒子数算法，通过调整粒子数维持样本集中的优质粒子获得较高的原始似然值^[22]。2015 年西班牙马德里查尔斯三世大学的 Elvira 和 Míguez 等人提出了一种通过检测 PF 后验分布收敛性来调整粒子数的 PF 算法，并设置了一系列的阈值对样本规模进行硬性范围控制，但是该算法相对复杂，制约了其在实际应用场景中的应用^[23]。

相比与上述得到了深入研究的单目标 PF 算法，多目标 PF 算法研究历史较短，其发展也较缓慢。2003 年，Boers 在泰雷兹公司资助下第一次提出了多目标 PF 算法。该算法虽然在目标数较少的仿真场景中效果不错，但是采用了简单的状态转移概作重要性函数，当目标数增多时，算法计算量呈指数增长^[24]。

针对 Boers 的多目标算法存在的维数灾难的问题，剑桥大学的 Orton 基于提出了多目标独立分区交叉采样的思想^[25]。独立分区交叉采样技术通过目标后验概率独立假设（posterior independence assumption, PIA），实现降维处理，从而把多维的目标状态问题变成多个一维的单目标跟踪问题，大大降低了算法复杂度。Kreucher 基于这种基于 PIA 的独立采样技术，提出了独立分区粒子滤波算法，然而该算法基于目标在空间上彼此相互区隔的前提假设，在目标临近时不再成立，引起算法跟踪性能恶化^[26]。

针对多目标相互临近时后验独立假设不再成立的问题，澳大利亚墨尔本大学的 Morelande 与美国通用动力公司 Kreucher 和 Kastella 提出了一种基于最优重要性密度联合采样（Joint Optimal Importance Density, JOID）的粒子滤波检测前跟踪算法，但该算法计算量与目标数目呈指数增长^[28]。2012 年西班牙马德里理工大学的 Ángel 和 Jesús 等提出了一种双层粒子滤波器（two-layer particle filter）^[30-31]，该算法使用量测信息同时对两个粒子滤波器进行更新，其中一个粒子滤波器通过似然比检验来检测新目标，确认目标后传递给另一个粒子滤波器用于的目标跟踪、航迹维持和终止，通过仿真实验说明其较好解决了目标的航迹起始问题。

国内大多数研究主要集中于单目标粒子滤波算法。2008 年，西安电子科技大学的龚亚信博士提出了将序贯概率比检验和固定样本长度似然比检验结合的 TBD 处理方法，实现了对弱目标的 TBD 处理，在此基础上，进一步提出自适应多模型（Adaptive Multiple Model, AMM）粒子滤波算法，通过仿真实验验证了对有机动特性的弱目标能够有效进行 TBD 处理，但是并未将算法向多目标场景推广^[32]。2012 年，电子科技大学的易伟博士针对临近目标干扰和观测模糊的问题，对 Morelande 提出的 JOID 方法加以改进，提出了基于独立采样的 IJOID-PF 算法，大

大减少了算法所需的粒子数，同时也证明了后验概率独立性假设有助于获得较好的先验蒙特卡洛分布^[33-34]。

总而言之，基于粒子滤波的 TBD 算法当下已经成为了国内外雷达领域目标检测与跟踪算法方向的研究热点。虽然众多国内外学者针对该研究方向做了许多的研究和工作的，但是，在多目标 PF-TBD 研究领域，还依然存在着如多目标维数灾难、临近目标的检测跟踪、粒子数的自适应选择等诸多问题，有待进一步解决和完善。

1.3 本文主要工作

本文研究了用于多目标检 PF-TBD 算法，论文组织结构如图 1-3 所示。第二章主要介绍了贝叶斯推理框架下的目标跟踪理论和经典的粒子滤波算法，在此基础上引入了多目标粒子滤波的 JMPD 模型。第三章针对维数灾难问题研究了独立分区粒子滤波算法，并针对临近目标干扰提出了并行分区状态采样的粒子滤波算法。第四章针对粒子数设置并提出了基于 KLD 变粒子数采样的并行分区粒子滤波算法。第五章利用本文提出的算法对两批声呐实测数据实现了 TBD 处理。

论文共有五章，具体章节内容如下：

第一章，介绍了本文的课题背景、研究意义和国内外粒子滤波领域的研究动态，并对本文主要研究内容做出介绍。

第二章，主要介绍了粒子滤波算法基础理论，它是第三章和第四章多目标粒子滤波算法的基础。2.1 节介绍了贝叶斯推理框架。2.2 节介绍粒子滤波的基本理论，分别介绍了序贯重要性采样和重采样两大组成部分，并推导了经典的采样重要性重采样算法和辅助粒子滤波的流程。在 2.3 节介绍了多目标的贝叶斯估计理论，同时给出了一种基于联合多目标概率密度模型的多目标的运动模型和量测模型，将 PF 算法模型扩展到多目标领域。2.4 节对经典的粒子滤波方法进行了仿真验证。

第三章，主要阐述了多目标粒子滤波面对的维数灾难和临近目标干扰问题，并通过改进独立分区方法，推导了本文提出的并行分区粒子滤波方法。3.1 节针对多目标跟踪的维数灾难问题，研究了独立分区交叉采样技术，并在此基础上研究了一种典型的独立分区粒子滤波算法，该算法通过将高维度的多目标联合采样降维成为多个单目标采样，从而使得计算量与目标数线性相关。3.2 节针对 IP-PF 算法无法解决的目标临近干扰问题，提出了基于并行分区状态采样的粒子滤波 TBD 算法。3.3 节通过仿真实验对比了两种多目标粒子滤波算法，验证了并行分区粒子滤波算法在处理临近目标时优于独立分区方法的性能。

第四章，主要研究了一种以后验估计精度为依据的粒子规模自适应设置方法。

4.1 节介绍了 KL 距离的基本理论，将 KL 距离引入以衡量先验分布和目标真实后验分布函数的差异，并将其应用于粒子滤波的粒子数设置中，推导出以后验分布估计精度为依据的粒子数计算公式。随后将推导出的粒子数计算公式应用于第三章中的并行分区粒子滤波算法中，提出了多目标 KLD-PP-PF 算法。4.2 节通过仿真实验和分析，验证了该算法的有效性，说明了它能在保证精度的前提下，避免传统粒子滤波方法预设固定粒子数的盲目性，达到了减少计算量的目的。

第五章使用本文提出的 KLD-PP-PF 算法对水声实测数据实现了 TBD 处理。

5.1 节针对无源声呐多目标检测跟踪问题，研究了多目标粒子滤波 TBD 的工程实现方案。5.2 节利用多目标粒子滤波检测前跟踪算法对两批某型无源声呐实测数据的离线处理，并对处理结果进行了详细的分析，离线处理结果证明了本文所提算法的有效性。

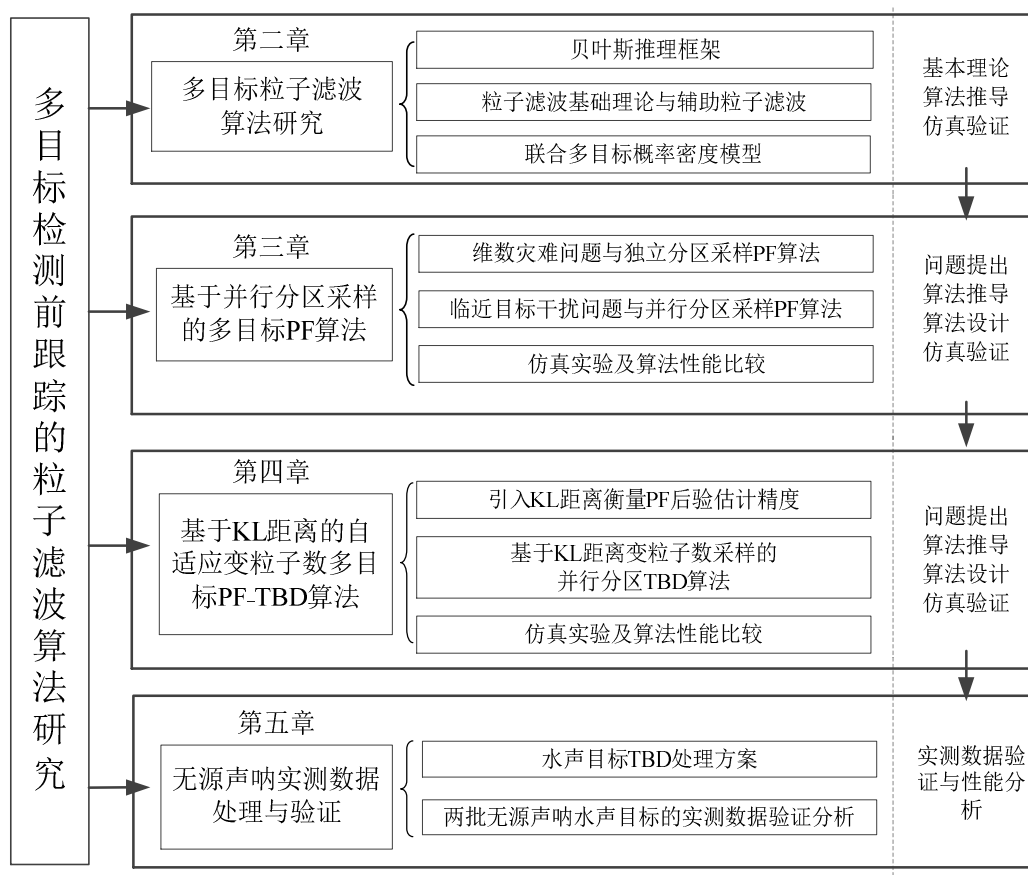


图 1-3 本文组织结构

第二章 多目标粒子滤波检测前跟踪算法

贝叶斯推理理论是当下各类型跟踪算法理论的基础框架。如经典的卡尔曼滤波器即贝叶斯估计器在线性高斯系统模型下的最优实现；而在非线性非高斯系统模型下，贝叶斯推理的次优实现包括基于网格的滤波器（Grid-based filter）^[35]、扩展卡尔曼滤波^[36]、无味卡尔曼滤波^[37]和粒子滤波^[38]等。粒子滤波算法作为一种十分有效的贝叶斯推理算法，具有便于计算、有可证明的收敛性且场景普适^[1]的优点，也因此得到了广泛而深入的研究和应用。

然而基于粒子滤波的目标跟踪算法依然存在不少问题有待进一步研究和解决。比如，在目标跟踪监视区域内，待检测跟踪的目标往往不止一个，相比于已得到各国研究者深入探讨的单目标粒子滤波算法，多目标粒子滤波算法的研究尚存不足，还面临着诸如维数灾难、临近目标干扰^[3]、粒子数的合理设定等难点。

2.1 状态空间模型与贝叶斯推理框架

对于目标检测和跟踪问题，一般在状态空间模型（state space model）下对问题进行描述。首先把目标实际状态和传感器对目标的观测值描述为两个不断演化的时间序列：目标状态矢量（state vector）和量测信息（measurements）。其中，状态矢量包含具体问题中涵括的所有目标运动学特征，如常见的目标位置、速度、加速度（而在其他领域如计量经济学的时间序列分析中，关心的可能是资金流、收益率、通货膨胀率等系统状态特征），对目标的状态矢量实现尽可能准确而及时的估计是观测者意图达成的最终目的，对观测者来说当然是未知的；而量测信息则是观测者可以获得的对目标状态的观测，如雷达系统可以得到的方位角、速度、回波强度等量测信息，量测与状态关联紧密，但又必然受到各种量测噪声的干扰。状态空间模型在处理多维问题和非线性、非高斯噪声模型下的问题时非常方便，相比于传统的时间序列分析技术，展现出巨大的优越性^[26]。

在动态系统的状态估计中，通常采用离散时间方法，使用差分方程对系统的时变过程进行描述，并且假设每一个离散时刻的量测都是可以取得的，这些模型的概率表达形式亦可得到。为搭建对动态系统的时变过程进行分析、推断的框架，至少需要建立两个基础模型：系统模型（system model）和量测模型（measurement model）。其中，第一个系统模型描述的是系统状态随时间的推演，在跟踪问题中，由于所关心的系统状态即目标运动学特征，故亦被称为目标运动模型（target dynamic model）；第二个量测模型描述的则是状态矢量与量测信息之间的统计关联。对于这样一个

概率形式表述的状态空间模型和在每个离散时刻更新量测信息的系统，一个贝叶斯递推估计是非常合适的解决途径。

令 $\{\mathbf{x}_k, k \in \mathbf{N}\}$ 表示随离散时间 k 不断演进的目标状态矢量，系统模型可以表示为

$$\mathbf{x}_k = f_k(\mathbf{x}_{k-1}, \mathbf{v}_{k-1}) \leftrightarrow \text{状态转移概率函数}, p(\mathbf{x}_k | \mathbf{x}_{k-1}) \quad (2-1)$$

其中 $\{\mathbf{v}_{k-1}, k \in \mathbf{N}\}$ 是独立同分布的过程噪声， $f_k(\cdot)$ 为一个关于 $k-1$ 时刻的状态 \mathbf{x}_{k-1} 和过程噪声 \mathbf{v}_{k-1} 的函数， $f_k(\cdot)$ 可能为一个非线性函数。

定义 k 时刻得到的量测信息为 \mathbf{z}_k ，量测模型可以表示为

$$\mathbf{z}_k = g_k(\mathbf{x}_k, \mathbf{n}_k) \leftrightarrow \text{量测似然函数}, p(\mathbf{z}_k | \mathbf{x}_k) \quad (2-2)$$

其中 $\{\mathbf{n}_k, k \in \mathbf{N}\}$ 是独立同分布的量测噪声， $g_k(\cdot)$ 为一个关于 k 时刻目标状态 \mathbf{x}_k 和量测噪声 \mathbf{n}_k 的函数， $g_k(\cdot)$ 也可能是非线性函数。

如图 2-1 所示，式(2-1)和式(2-2)一同定义了跟踪问题所需的状态空间模型，箭头表示各变量之间的依赖关系。图中虚线以上部分是对观测者隐藏不可见的目标实际状态，它是一个一阶马尔卡夫过程，即当前时刻状态只和前一时刻目标状态相关，其依赖关系为状态转移概率 $p(\mathbf{x}_k | \mathbf{x}_{k-1})$ 所定义；图中虚线以下部分是对观测者可见的量测信息，它与当前目标状态有关，其依赖关系为似然函数 $p(\mathbf{z}_k | \mathbf{x}_k)$ 所定义。由于这样的特性，类似的模型在离散贝叶斯推断中也被形象地称为隐马尔科夫模型（Hidden Markov Model, HMM）。

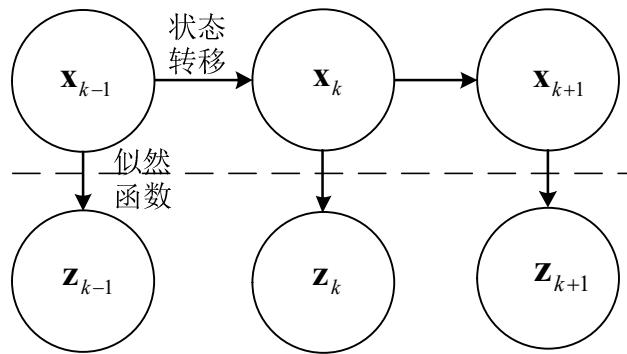


图 2-1 状态空间模型示意图

通常，贝叶斯推理框架假设背景噪声分布是已知的，即量测噪声 n_k 被假定为已知分布（如瑞利分布等）且相互独立。此时，跟踪问题的目标可以被描述为：基于直到 k 时刻的所有可得的量测信息 对 \mathbf{x}_k 的状态进行估计。

从贝叶斯递推的观点来看,跟踪问题就是在已知所有可得的量测信息 $\mathbf{Z}_{1:k}$ 的条件下,迭代地估计 \mathbf{x}_k 在 k 时刻取各个值的概率大小。用概率语言描述,即就要求估计一个条件后验概率密度函数 $p(\mathbf{x}_k | \mathbf{Z}_{1:k})$ 。假设初始的后验概率密度等于初始状态矢量,即先验概率已知,

$$p(\mathbf{x}_0 | \mathbf{z}_0) \equiv p(\mathbf{x}_0) \quad (2-3)$$

其中, \mathbf{z}_0 表示没有观测时的观测矢量的初始状态。则理论上,使用式(2-1)的系统模型和(2-2)的量测模型,在贝叶斯推理中有两大重要部分,分别是预测阶段和更新阶段,通过实现这两个环节的运算,可以迭代地得到所需要的后验概率密度函数 $p(\mathbf{x}_k | \mathbf{Z}_{1:k})$ 。

预测阶段指利用系统模型来得到 k 时刻的先验概率,由 Chapman—Kolmogorov 方程可得:

$$p(\mathbf{x}_k | \mathbf{Z}_{1:k-1}) = \int p(\mathbf{x}_k | \mathbf{x}_{k-1}) p(\mathbf{x}_{k-1} | \mathbf{Z}_{1:k-1}) d\mathbf{x}_{k-1} \quad (2-4)$$

注意在上式中,系统模型为一个一阶马尔科夫过程。状态转移函数的 $p(\mathbf{x}_k | \mathbf{x}_{k-1})$ 统计模型由系统方程和已知的过程噪声 \mathbf{v}_k 的统计特性共同决定。

更新阶段指的是使用在 k 时刻取得的新量测 \mathbf{z}_k 用于更新先验概率,由贝叶斯定理可得,

$$p(\mathbf{x}_k | \mathbf{Z}_{1:k}) = \frac{p(\mathbf{z}_k | \mathbf{x}_k) p(\mathbf{x}_k | \mathbf{Z}_{1:k-1})}{p(\mathbf{z}_k | \mathbf{Z}_{1:k-1})} \quad (2-5)$$

其中分母上的归一化常数为

$$p(\mathbf{z}_k | \mathbf{Z}_{1:k-1}) = \int p(\mathbf{z}_k | \mathbf{x}_k) p(\mathbf{x}_k | \mathbf{Z}_{1:k-1}) d\mathbf{x}_k \quad (2-6)$$

该常数取决于量测似然函数 $p(\mathbf{z}_k | \mathbf{x}_k)$, 似然函数由量测模型和已知的量测噪声 \mathbf{n}_k 的统计特性共同决定。

式(2-4)和(2-5)描述的预测、更新两个阶段的迭代关系构成了贝叶斯推理的基础框架。进一步可以证明的是,在线性高斯模型的动态系统下,卡尔曼滤波器即贝叶斯推理的最优解。然而,这个后验概率的迭代过程只是一种理论上的解决方案,在工程实际中更广泛存在的非线性动态系统下,式(2-4)和(2-5)中的积分运算使得解析解无法得到。一种解决方法是通过蒙特卡洛随机采样,把积分离散化处理为有限样本的求和,对最优解进行逼近。本文研究这样一种通过离散样本近似实现贝叶

斯估计的粒子滤波算法。

2.2 粒子滤波算法的基础理论

序贯蒙特卡洛 (Sequential Monte Carlo, SMC) [27-28] 方法是各种粒子滤波算法的基础。顾名思义, SMC 方法包含两层意思, “蒙特卡洛”方法指的是通过随机采样获取样本 (即粒子), 然后以这一群加权的离散样本之和来逼近目标概率分布的思想; 而“序贯”则指的是 SMC 方法是一种“在线”(online) 的估计方法, 通过不断地将某一时刻的粒子群及其权值集合向下一时刻迭代更新, 实现贝叶斯递推估计[29]。序贯重要性采样算法即这样的一种 SMC 方法的具体实现。

2.2.1 序贯重要性采样

序贯重要性采样 (Sequential Importance Sampling, SIS) 是一种重要的 SMC 方法。令 $\mathbf{x}_{0:k} = \{\mathbf{x}_j, j=0, \dots, k\}$ 表示 $0 \sim k$ 时刻的目标状态, $\mathbf{Z}_{1:k} = \{\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_k\}$ 表示 $1 \sim k$ 时刻的量测, 为了估计目标状态的后验概率 $p(\mathbf{x}_{0:k} | \mathbf{Z}_{1:k})$, 设 $\{\mathbf{x}_{0:k}^i, i=0, \dots, N\}$ 是粒子状态集合, $\{w_k^i, i=1, \dots, N\}$ 是赋予对应粒子的归一化权重集合, 即满足 $\sum_i w_k^i = 1$, N 为粒子数。目标后验 $p(\mathbf{x}_{0:k} | \mathbf{Z}_{1:k})$ 可以用如下求和逼近

$$p(\mathbf{x}_{0:k} | \mathbf{Z}_{1:k}) \approx \sum_{i=1}^N w_k^i \delta(\mathbf{x}_{0:k} - \mathbf{x}_{0:k}^i) \quad (2-7)$$

其中 $\delta(\bullet)$ 是 Dirac 函数。

此时的问题变为如何获得这样一簇加权粒子集 $\{\mathbf{x}_{0:k}^i, w_k^i\}_{i=1}^N$ 。对未知的 $p(\mathbf{x}_{0:k} | \mathbf{Z}_{1:k})$ 进行采样得到粒子及其权重显然是无法做到的, 后验概率密度函数正是待求的未知分布, 直接对其采样无疑难以实现。为了解决这个矛盾, 首先引入重要性采样 (Importance Sampling, IS) 方法。

IS 方法的基本思想是: 设作为目标的概率密度 $p(x)$ 难以被直接采样, 但存在另外一个易于求得分布 $\pi(x)$ 且二者成比例关系 $p(x) \propto \pi(x)$, 另外引入一个已知的且容易采样的重要性密度函数 $q(\cdot)$, 对其采样可得到粒子集 $\{\mathbf{x}^i\}_{i=1}^N$ 。那么, 通过对该样本集合适地赋权, 用这一组带权重的离散样本 $\{\mathbf{x}^i, w^i\}_{i=1}^N$ 之和即可近似表征原采样目标 $p(x)$ 的分布, 即

$$p(x) \approx \sum_{i=1}^N w^i \delta(x - \mathbf{x}^i) \quad (2-8)$$

其中权值 w^i 大小可以如下计算

$$w^i \propto \frac{\pi(x^i)}{q(x^i)} \quad (2-9)$$

注意到由于权值计算通常包含权重归一化，故权值计算多以比例式表示。同理，设从重要性密度函数 $q(\mathbf{x}_{0:k} | \mathbf{Z}_{1:k})$ 采样得到粒子集 $\{\mathbf{x}_{0:k}^i, i=1, \dots, N\}$ ，根据重要性采样原理，粒子的权重可以表示为

$$w_k^i \propto \frac{p(\mathbf{x}_{0:k}^i | \mathbf{Z}_{1:k})}{q(\mathbf{x}_{0:k}^i | \mathbf{Z}_{1:k})} \quad (2-10)$$

本节开头提到，序贯处理是 SMC 方法的一大特征。SIS 算法即通过提出合适的重要性函数，使得粒子和权重得以序贯地迭代更新。为了推导关于权重计算的递推关系式，根据乘法公式，将目标后验 $q(\mathbf{x}_{0:k} | \mathbf{Z}_{1:k})$ 分解为递推形式

$$q(\mathbf{x}_{0:k} | \mathbf{Z}_{1:k}) = q(\mathbf{x}_k | \mathbf{x}_{0:k-1}, \mathbf{Z}_{1:k}) q(\mathbf{x}_{0:k-1} | \mathbf{Z}_{1:k-1}) \quad (2-11)$$

式(2-11)在物理意义上对应于如下的样本集的扩维过程，

$$\{\mathbf{x}_{0:k}^i\} = \{\mathbf{x}_{0:k-1}^i, \mathbf{x}_k^i\}, i=1, \dots, N \quad (2-12)$$

表示将当前时刻新采样得到的粒子集 $\mathbf{x}_k^i \sim q(\mathbf{x}_{0:k-1} | \mathbf{Z}_{1:k})$ 加入历史样本集 $\mathbf{x}_{0:k-1}^i \sim q(\mathbf{x}_{0:k-1} | \mathbf{Z}_{1:k-1})$ ，得到新的全体样本集合。

根据贝叶斯公式， $p(\mathbf{x}_{0:k} | \mathbf{Z}_{1:k})$ 也可以表示为如下形式

$$\begin{aligned} p(\mathbf{x}_{0:k} | \mathbf{Z}_{1:k}) &= \frac{p(\mathbf{z}_k | \mathbf{x}_{0:k}) p(\mathbf{x}_{0:k} | \mathbf{Z}_{1:k-1})}{p(\mathbf{z}_k | \mathbf{Z}_{1:k-1})} \\ &= \frac{p(\mathbf{z}_k | \mathbf{x}_k) p(\mathbf{x}_k | \mathbf{x}_{0:k-1})}{p(\mathbf{z}_k | \mathbf{Z}_{1:k-1})} p(\mathbf{x}_{0:k-1} | \mathbf{Z}_{1:k-1}) \end{aligned} \quad (2-13)$$

将公式(2-13)代入公式(2-11)后，即可得到权重计算的递推方程，

$$w_k^i \propto w_{k-1}^i \frac{p(\mathbf{z}_k | \mathbf{x}_k^i) p(\mathbf{x}_k^i | \mathbf{x}_{k-1}^i)}{q(\mathbf{x}_k^i | \mathbf{x}_{0:k-1}^i, \mathbf{Z}_{1:k})} \quad (2-14)$$

由于目标状态服从一阶马尔科夫过程，式(2-14)右侧分母可以进一步化简为 $q(\mathbf{x}_k | \mathbf{x}_{0:k-1}, \mathbf{Z}_{1:k}) = q(\mathbf{x}_k | \mathbf{x}_{k-1}, \mathbf{z}_k)$ 。即采样得到的粒子信息存储方式也是序贯的，跟踪系统在迭代中只需储存当前粒子状态 \mathbf{x}_k^i ，而在更新时直接覆盖吊粒子的历史状态，此时粒子的权重递推公式为

$$w_k^i \propto w_{k-1}^i \frac{p(\mathbf{z}_k | \mathbf{x}_k^i) p(\mathbf{x}_k^i | \mathbf{x}_{k-1}^i)}{q(\mathbf{x}_k^i | \mathbf{x}_{k-1}^i, \mathbf{z}_k)} \quad (2-15)$$

2.2.2 粒子退化与重采样

在 2.2.1 节介绍的重要性采样及其权重计算的方法是 SIS 算法的主要思想，在较短的时间序列上可以得到成功的应用。然而，粒子滤波器将会因为迭代次数的增加以及时间的退场而面临十分严重的权值退化问题。权重退化指的是这样一种现象，即仅仅少量粒子拥有几乎全部权重，而其余大量粒子的权重退化到可以忽略不计，这批无效粒子虽然消耗了大量的计算和存储资源，但最终在式(2-7)的求和中，因为权重很低而无法对目标状态的估计做出有效贡献。

在 SIS 算法的递归计算中，粒子退化问题的出现几乎难以避免。从理论上来看，缓解粒子退化问题的暴力方法是使用一个足够多的粒子数目，但由此巨大的计算量往往是实际应用中难以接受的。通常，解决粒子退化问题遵循另外两种思路对 SIS 算法进行改进：1) 对粒子进行重采样；2) 提出更接近真实后验概率的重要性密度函数。本小节将介绍前者；2.2.5.1 小节对后者进行了推导。




图 2-2 粒子重采样示意图

粒子重采样的基本思路是：依据某种准则，复制高权重粒子去替换掉低权重粒子，这样既使得匹配真实分布的粒子继续参与迭代，也能保证粒子总数保持不变，便于进行递归计算。重采样效果如图 2-2 所示。在引入重采样之前，提出一个称为有效粒子数 N_{eff} 的参数来衡量粒子权重有效程度^[1]，定义为

$$N_{eff} = N / (1 + \text{var}(v_k^{*i})) \quad (2-16)$$

其中， v_k^{*i} 被称为“真实权值” (true weight) ^[1]， $v_k^{*i} = p(\mathbf{x}_k^i | \mathbf{z}_{1:k}) / q(\mathbf{x}_k^i | \mathbf{x}_{k-1}^i, \mathbf{z}_{1:k})$ ，实际计算中，可以使用粒子归一化权重对 N_{eff} 进行估算

$$\hat{N}_{eff} = \frac{1}{\sum_{n=1}^N (w_k^i)^2} \quad (2-17)$$

其中 w_k^i 为归一化权重。

目前对各种重采样算法的研究已经比较丰富，例如系统重采样、残差重采样以及分层采样等^[39-41]。本文中选择系统重采样算法，其伪代码实现如表 2-1 所示。

虽然重采样能够较为有效地解决粒子退化所带来的挑战，但是该技术也同时引入了一些新的问题。首先，重采样过程复制高权重的粒子去覆盖低权重的粒子，在严重退化的粒子集中得到的粒子可能几乎完全来自极少数高权重粒子，不断降低随机采样的多样性，导致粒子匮乏或称粒子贫化现象的出现，将降低滤波器对量

表 2-1 系统重采样算法的伪代码实现

```


$$[\{\mathbf{x}_k^{j*}, w_k^j, i^j\}_{j=1}^N] = RESAMPLE [\{\mathbf{x}_k^i, w_k^i\}_{i=1}^N]$$


```

- 初始化概率分布函数 (CDF): $c_i = 0$
- FOR $i = 2: N$
 - 计算 CDF: $c_i = c_{i-1} + w_k^i$
- END FOR
- 从 CDF 起点开始: $i = 1$
- 随机选取一个起始点: $u_i \sim U[0, N^{-1}]$
- FOR $j = 1: N$
 - 沿 CDF 移动: $u_i = u_{i-1} + N^{-1}(j - 1)$
 - WHILE $u_j > c_i$
 - $i = i + 1$
 - END WHILE
 - $\mathbf{x}_k^{j*} = \mathbf{x}_k^i$
 - $w_k^j = N^{-1}$
 - $i^j = i$

测野值的鲁棒性；第二，进行一次重采样计算需要对全部粒子进行操作，破坏了序贯蒙特卡洛采样自身可在粒子间并行处理的良好性质，使得不同粒子的难以并行参与计算，不利于硬件实现。

2.2.3 使用粒子估计目标状态的实现

在得到近似贝叶斯目标后验的加权粒子集后，可根据不同的准则输出目标状态进行估计。常用的有期望后验（Expected a Posteriori, EAP）估计输出最小均方根误差（Minimum mean square error, MMSE）估计和最大后验概率（Maximum a Posterior, MAP）估计等。

本文采用 MMSE 准则，将 k 时刻粒子状态加权平均值输出作为对 k 时刻目标状态 MMSE 估计：

$$\hat{\mathbf{x}}_k(MMSE) = \sum_{i=1}^N w_k^i \mathbf{x}_k^i \quad (2-18)$$

2.2.4 单目标 SIR-TBD 算法

在对 SIS 算法的工程应用中，一种最常用且最直观的办法是选取状态转移概率作为重要性密度函数 $q(\cdot)$ ，一些文献中亦将其称为运动先验概率^[3]（Kinetic prior, KP），即令

$$q(\mathbf{x}_k | \mathbf{x}_{k-1}, \mathbf{z}_k) = p(\mathbf{x}_k | \mathbf{x}_{k-1}^p) \quad (2-19)$$

将式(2-19)代入权重计算式错误!未找到引用源。，可以看出选择 KP 进行采样的简洁性，此时粒子权重递推公式的因子被简化为量测的条件似然值

$$w_k^p = w_{k-1}^p p(\mathbf{z}_k | \mathbf{x}_k^p) \quad (2-20)$$

为了简化算法流程，也可省略 N_{eff} 的计算而在每一时刻都使用重采样步骤。习惯上，将这种选择 KP 作为 $q(\cdot)$ 且每轮迭代都进行重采样的简便算法称为采样重要性重采样（Sampling Importance Resampling, SIR）算法^[1]，这种易于实现的经典粒子滤波算法也被称为自举滤波器^[26]。

以下给出单目标 SIR-TBD 算法的实现步骤。

步骤 1 粒子初始化： $\{\mathbf{x}_0^p, w_0^p\}, p = 1, 2, \dots, N_{part}$

for $k = 1, \dots, K$

步骤 2 利用状态转移概率采样：对于每一个粒子 p ， $p = 1, \dots, N_{part}$

$$\mathbf{x}_k^p \sim q(\mathbf{x}_k | \mathbf{x}_{k-1}, \mathbf{z}_k) = p(\mathbf{x}_k | \mathbf{x}_{k-1}^p) \quad (2-21)$$

步骤 3 权重递推：对每一个 p ，计算 $w_k^p = w_{k-1}^p p(\mathbf{z}_k | \mathbf{x}_k^p)$ ；

步骤 4 权重归一化：使 w_p 和为 1， $w_p \leftarrow w_p / \sum_{i=1}^{N_{\text{part}}} w_i$ ；

步骤 5 重采样：使用如系统重采样算法对 N_{part} 个粒子重采样，根据由 w_p 的分布对 $\{\mathbf{x}^p, p=1, \dots, N_{\text{part}}\}$ 内粒子进行置换，重采样后 $w_k^p = 1/N$

步骤 6 对目标的状态进行估计。

end for

实际计算中，注意到每当步骤 5 重采样完成后，所有粒子被赋予均匀的权重 $1/N$ ，所以每一步都重采样的 SIR 算法在步骤 2 的权重计算时，式子右侧可以忽略上一步权重 w_{k-1}^p ，直接等于量测的似然函数，即简化为 $w_k^p = p(\mathbf{z} | \mathbf{x}_k^p)$ 。

2.2.5 辅助粒子滤波

在 2.2.4 节中给出的经典 SIR 算法中可以看到，为推测得到粒子在 k 时刻的位置，关键步骤之一是使用在上一时刻的粒子状态 \mathbf{x}_{k-1}^p 和当前量测 \mathbf{z}_k ，对重要性密度函数 $q(\mathbf{x}_k | \mathbf{x}_{k-1}, \mathbf{z}_k)$ 采样以生成当前时刻的加权粒子集。在粒子滤波相关的研究领域中，重要性密度函数（一些文献中亦称为提议分布或建议分布^[17]）的选择和设计是一个关键的研究课题，因为重要性密度函数的选取会对粒子滤波器的效率产生巨大的影响。本节介绍的辅助粒子滤波（Auxiliary particle filter, APF^[42]）算法即是这样一种重要的重要性密度函数设计方法，该算法试图通过引入下一时刻量测信息优化当前时刻的粒子采样，更广义地讲，它也可被认为是 SMC 方法中的前瞻采样（Lookahead sampling）^[43]或称试验性采样（Pilot sampling）的一种一步策略^[44]。

2.2.5.1 最优重要性密度函数

选择重要性概率密度函数的一个标准是使得 2.2.2 节介绍的真实权值 $\{v_k^{*i}\}_{i=1}^N$ 的方差最小。理论上可以证明，在此准则下，最优重要性密度函数（Optimal importance density, OID）或称最优核函数（Optimal kernel） $q(\mathbf{x}_k | \mathbf{x}_{k-1}^i, \mathbf{z}_k)_{\text{opt}}$ 为^[1]

$$\begin{aligned} q(\mathbf{x}_k | \mathbf{x}_{k-1}^i, \mathbf{z}_k)_{\text{opt}} &= p(\mathbf{x}_k | \mathbf{x}_{k-1}^i, \mathbf{z}_k) \\ &= \frac{p(\mathbf{z}_k | \mathbf{x}_k) p(\mathbf{x}_k | \mathbf{x}_{k-1}^i)}{p(\mathbf{z}_k | \mathbf{x}_{k-1}^i)} \end{aligned} \quad (2-22)$$

将式(2-22)推出的 OID 代入权重递推式错误!未找到引用源。，得到此时的权重更新方程为

$$\begin{aligned} w_k^i &\propto w_{k-1}^i p(\mathbf{z}_k | \mathbf{x}_{k-1}^i) \\ &= w_{k-1}^i \int p(\mathbf{z}_k | x') p(\mathbf{x}_k^i | \mathbf{x}_{k-1}^i) dx_k' \end{aligned} \quad (2-23)$$

但是这个密度函数显然无法被直接采样。实际操作中，如在经典的 SIR 算法中一样，重要性密度函数常被选为状态转移函数 $p(\mathbf{x}_k | \mathbf{x}_{k-1})$ 。然而，当粒子数一定时，选用更复杂的重要性密度函数可带来更好的结果。

重要性密度函数的选择不合适时可能造成大量的粒子处于低似然区域，仅有少量粒子在权值更新后获得到较高的权值，这将导致粒子权值迅速退化。图 2-3 展示了一个重要性密度函数与似然函数的分布失配（mismatch）的情形。图中，左侧概率分布函数表示状态后验 $p(\mathbf{x}_k | \mathbf{z}_{1:k-1})$ ，右侧概率分布函数表示似然分布 $p(\mathbf{z}_k | \mathbf{x}_k)$ ，下方样本点表示基于某一重要性采样函数 $q(\mathbf{x}_k)$ 采样所得的粒子样本。此时进行粒子权值更新，除了最右侧的几个粒子样本能被赋予有效似然值之外，其他粒子的似然值接近于零，权值方差很大，导致粒子权重退化问题将会非常严重。在这种场景下，粒子滤波算法将对异常扰动非常敏感，鲁棒性往往会大大降低。

进一步需要指出的是，在多目标场景下，由于状态空间维度高，似然函数分布常常比低维的场景下的分布更“陡峭”（有效似然的分布区域与整个状态空间的区域比值很小），此时对重要性密度函数的选择与设计尤需谨慎。由此可见，对于 OID 的近似（而不再简单选用状态转移函数），在问题维度增加时变得非常重要。




图 2-3 重要性密度函数与似然函数的分布失配示意图

2.2.5.2 引入量测信息优化重要性密度函数

辅助粒子滤波算法以经典的 SIS 算法为基础，引入一个重要性采样函数 $q(\mathbf{x}_k, i | \mathbf{z}_k)$ ，由该函数可以采样得到样本集 $\{\mathbf{x}_k^j, i^j\}_{j=1}^{N_{part}}$ ，其中 i^j 表示 $k-1$ 时刻的粒子索引标号表，由贝叶斯公式可得，

$$\begin{aligned} p(\mathbf{x}_k, i | \mathbf{z}_{1:k}) &\propto p(\mathbf{z}_k | \mathbf{x}_k) p(\mathbf{z}_k, i | \mathbf{z}_{1:k-1}) \\ &= p(\mathbf{z}_k | \mathbf{x}_k) p(\mathbf{x}_k | \mathbf{x}_{k-1}^i) w_{k-1}^i \end{aligned} \quad (2-24)$$

辅助粒子滤波算法从联合概率密度 $p(\mathbf{x}_k, i | \mathbf{z}_k)$ 中产生样本，然后省略粒子对 (\mathbf{x}_k, i) 中的索引标号 i ，从而从边缘概率密度 $p(\mathbf{x}_k | \mathbf{z}_k)$ 中产生样本 $\{\mathbf{x}_k^j, i^j\}_{j=1}^N$ 的重要

性密度需要满足如下的关系式：

$$q(\mathbf{x}_k, i | \mathbf{z}_{1:k}) \propto p(\mathbf{z}_k | \mu_k^i) p(\mathbf{x}_k | \mathbf{x}_{k-1}^i) w_{k-1}^i \quad (2-25)$$

其中， μ_k^i 是用来表示 \mathbf{x}_k 在条件 \mathbf{x}_{k-1} 下的一个特征，这个特征量可以是期望 $\mu_k^i = E[\mathbf{x}_k | \mathbf{x}_{k-1}^i]$ 也可以是一个样本 $\mu_k^i \sim p(\mathbf{x}_k | \mathbf{x}_{k-1}^i)$ ，由式(2-24)可得

$$q(\mathbf{x}_k, i | \mathbf{z}_{1:k}) = q(i | \mathbf{z}_{1:k}) q(\mathbf{x}_k | i, \mathbf{z}_{1:k}) \quad (2-26)$$

对等号右侧部分 $q(\mathbf{x}_k | i, \mathbf{z}_{1:k})$ 作如下定义

$$q(\mathbf{x}_k | i, \mathbf{z}_{1:k}) \triangleq p(\mathbf{x}_k | \mathbf{x}_{k-1}^i) \quad (2-27)$$

联立式(2-25)与式(2-26)，可以得到

$$q(i | \mathbf{z}_{1:k}) \propto p(\mathbf{z}_k | \mu_k^i) w_{k-1}^i \quad (2-28)$$

接下来就可以给样本集 $\{\mathbf{x}_k^j, i^j\}_{j=1}^{N_{part}}$ 分配权重，根据 2.2.1 小节所介绍的重要性采样原理，其权值与式(2-24)和式(2-25)右侧之比成正比，即

$$\begin{aligned} w_k^j &\propto w_{k-1}^{i^j} \frac{p(\mathbf{z}_k | \mathbf{x}_k^j) p(\mathbf{x}_k^j | \mathbf{x}_{k-1}^{i^j})}{q(\mathbf{x}_k^j, i^j | \mathbf{z}_{1:k})} \\ &= \frac{p(\mathbf{z}_k | \mathbf{x}_k^j)}{p(\mathbf{z}_k | \mu_k^{i^j})} \end{aligned} \quad (2-29)$$

在(2-29)式子中，值得注意的是，对比标准 SIR 算法的权值计算公式(2-20)，辅助粒子滤波在分母上用 $p(\mathbf{z}_k | \mu_k^{i^j})$ 来修正辅助变量采样而引入的偏差。

参照 2.2.4 节介绍的 SIR 算法，结合辅助滤波算法的思路，可以得到辅助采样重要性重采样（Auxiliary Sampling Importance Resampling, ASIR）算法。

ASIR 算法一次迭代的实现流程如下：

for $i = 1, \dots, N_{part}$

步骤 1 引入辅助变量采样得到 μ_k^i ， $\mu_k^i \sim p(\mathbf{x}_k | \mathbf{x}_{k-1}^i)$

步骤 2 计算粒子一阶权重， $w_k^i = q(i | \mathbf{z}_{1:k}) \propto w_{k-1}^i p(\mathbf{z}_k | \mathbf{x}_k^i)$

步骤 3 一阶权重归一化， $w^j \leftarrow w^j / \sum_{i=1}^{N_{part}} w^j$

end for

步骤 4 重采样，基于一阶权重筛选权重高的优质粒子 \mathbf{x}_{k+1}^j 的标号，并回溯找出在 k 时刻其对应的粒子 i ，

$$\left[\left\{ -, -, i^j \right\}_{j=1}^{N_{part}} \right] = RESAMPLE \left[\left\{ \mathbf{x}_k^i, w_k^i \right\}_{j=1}^{N_{part}} \right] \quad (2-30)$$

注意到，本次重采样只需输出粒子母本标号序列 i^j ，即步骤 2 之后，辅助采样的粒子状态 μ_{k+1}^i 即可丢弃。

for $j = 1, \dots, N_{part}$

步骤 6 如同 SIR 算法一样，根据先验分布进行采样： $\mathbf{x}_{k+1}^j \sim p(\mathbf{x}_{k+1} | \mathbf{x}_k^{i^j})$ ，注意到 $\mathbf{x}_k^{i^j}$ 表示只有优质母本进行了状态转移。

步骤 7 根据式(2-29)计算二阶权重，注意到分母上使用了第一步采样中优质子本的一阶权重进行修正

$$w_{k+1}^j = \frac{p(\mathbf{z}_{k+1}^i | \mathbf{x}_{k+1}^j)}{p(\mathbf{z}_{k+1} | \mu_{k+1}^{i^j})} \quad (2-31)$$

步骤 8 权重归一化， $w^j \leftarrow w^j / \sum_{j=1}^{N_{part}} w^j$

end for

步骤 9 对目标状态进行估计。

总的来说，APF 共经过两次 $k-1$ 时刻到 k 时刻的采样，第一次采样是试验性采样，并依据 k 时刻量测赋权（一阶权重），以重采样筛选出优质粒子标号 j ，而不必保存粒子状态 μ_{k+1}^i ；然后带着标号 j 序列回溯到 k 时刻，寻找这些优质粒子的母本。随后以这些母本为基础重新向 k 时刻进行状态转移。若将 SIR 算法流程描述为“采样-重采样”，与之相反的，可以将 APF 算法的流程称为“重采样-采样”。

2.3 多目标跟踪的联合多目标概率密度模型

对于粒子滤波 TBD 算法的大量早期研究都着眼于单目标的情况，但目标跟踪的现实应用场景中，待检测跟踪的目标通常不止一个。显然，如何将理想化的单目标粒子滤波 TBD 算法推广到更一般化的多目标场景中，是值得进一步研究探讨的。

2.3.1 多目标检测跟踪的贝叶斯推理建模

本小节首先将 2.2 节介绍的贝叶斯推理框架向多目标场景作一般化的推广，讨论对多个具有多维连续值状态的目标矢量和随机运动特征的目标进行跟踪的方法。

为了便于讨论本文所关注的多目标跟踪（Multi-target tracking, MTT）场景，以下做出两个假设：

假设 1： 监视区域内目标数量是已知的。

假设 2： 目标运动是互相独立的。

在假设 1 所关注的场景下，基于联合多目标概率密度函数（Joint multitarget probability density, JMPD）的粒子滤波器提供了一个可以在贝叶斯场景下递归跟踪多目标的手段。基于 JMPD 的方法不需要观测与航迹的直接关联，其基本思路是将多个单目标状态变量合并为一个多目标状态变量，另外扩展目标数目作为一个状态变量，即赋予每一个粒子全部目标状态的信息和目标总数目。

进一步的，设在 k 时刻共有 T 个目标，其状态矢量依次为 $\mathbf{x}_1^k, \mathbf{x}_2^k, \dots, \mathbf{x}_{T-1}^k, \mathbf{x}_T^k$ ，则条件后验概率密度 $p(\mathbf{x}_1^k, \mathbf{x}_2^k, \dots, \mathbf{x}_{T-1}^k, \mathbf{x}_T^k | \mathbf{Z}^k)$ 即可表示在 k 时刻基于一组过去的观测 \mathbf{Z}^k 的多目标状态。量测集 \mathbf{Z}^k 是指从起始一直到 k 时刻收集的量测，即 $\mathbf{Z}^k = \{\mathbf{z}^1, \mathbf{z}^2, \dots, \mathbf{z}^k\}$ ，其中每个 \mathbf{z}^i 是 i 时刻的一个量测值或一个量测矢量。在密度函数 $p(\mathbf{x}_1^k, \mathbf{x}_2^k, \dots, \mathbf{x}_{T-1}^k, \mathbf{x}_T^k | \mathbf{Z}^k)$ 中的每一个状态矢量 \mathbf{x}_i 都是形式例如 $[x, y, \dot{x}, \dot{y}]$ 的矢量。我们称 T 个目标状态矢量 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_{T-1}, \mathbf{x}_T$ 中的每一个为多目标状态 \mathbf{X} 的一个划分或“子分区”（partition）。为方便起见，可以将密度函数写成更紧凑的格式 $p(\mathbf{X}^k, T^k | \mathbf{Z}^k)$ ，表示状态矢量 \mathbf{X} 包括数量未知的多个目标且每一个目标都有其自己的状态矢量。JMPD 表示方法可以举例如下：

$p(\emptyset, T=0 | \mathbf{Z})$ ，表示监视区域内没有目标时的后验概率密度函数；

$p(\mathbf{x}_1, T=1 | \mathbf{Z})$ ，表示状态为 \mathbf{x}_1 的单目标后验概率密度函数；

$p(\mathbf{x}_1, \mathbf{x}_2, T=2 | \mathbf{Z})$ ，表示状态分别为 \mathbf{x}_1 和 \mathbf{x}_2 的两个目标的后验概率密度函数；

$p(\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3, T=3 | \mathbf{Z})$ ，表示状态分别为 \mathbf{x}_1 ， \mathbf{x}_2 和 \mathbf{x}_3 的三个目标的后验概率密度函数。

需要注意的是，在使用 JMPD 设计的多目标跟踪算法中，目标状态矢量具有物理意义（而非数学意义）上的排列不变性。例如，多目标状态 $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2]$ 和 $\mathbf{X} = [\mathbf{x}_2, \mathbf{x}_1]$ 指的是同一个物理事件，即监视区域内有两个目标，一个的状态是 \mathbf{x}_1 ，另一个的是 \mathbf{x}_2 。无论单目标状态矢量的组成元素是什么这一点都是正确的。即使单目标状态矢量包含目标的识别号甚至是目标序列号，JMPD 的排列的不变性依然存在。

基于 JMPD 的方法中，诸如 $p(\mathbf{z} | \mathbf{X}, T)$ 的似然函数和如 $p(\mathbf{X}, T | \mathbf{Z})$ 的 JMPD 都是要根据概率与统计定理进行操作的传统的贝叶斯对象。因此，一个多目标系统的状态为 $\mathbf{X} = (\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_{T-1}, \mathbf{x}_T)$ ，其 pdf 为 $p(\mathbf{x}_1, \dots, \mathbf{x}_T, T | \mathbf{Z})$ ， T 为变量。这可以被看作一个由离散随机变量 T 控制 \mathbf{X} 的维度的混合随机系统。

设系统内存在 T 个目标，其概率由边缘分布表征为

$$p(T | \mathbf{Z}) = \int d\mathbf{x}_1 \cdots d\mathbf{x}_T p(\mathbf{x}_1, \dots, \mathbf{x}_T, T | \mathbf{Z}) \quad (2-32)$$

作为一个边缘分布，其归一化系数为

$$\sum_{T=0}^{\infty} p(T|\mathbf{Z}) = 1 \quad (2-33)$$

如果目标广泛地分散在传感器的量测空间，每一个目标的量测可以被独立地与目标关联，那么联合多目标后验密度就近似相乘。在这种条件下，这个多目标问题就可以被看作一组单目标问题。然而，多目标跟踪的特点即总的来说，一些量测与目标的关联模糊，因此，条件概率密度并非相乘关系。

后验概率密度函数随时间的更新依据贝叶斯推理进行。JMPD 随时间演化的模型由状态转移概率 $p(\mathbf{X}^k, T^k | \mathbf{X}^{k-1}, T^{k-1})$ 表征，它在概率意义上描述了状态随时间变化的过程，该概率包括了目标运动模型，也可表示目标的出现和消失，以及其他具体问题可能涉及的诸如地形和道路图等的其他先验信息。

应用 Chapman-Kolmogorov 方程，JMPD 随时间更新后的预测密度由状态更新方程计算得到：

$$\begin{aligned} & p(\mathbf{X}^k, T^k | \mathbf{Z}^k) \\ &= \sum_{T^{k-1}=0}^{\infty} \int d\mathbf{X}^{k-1} p(\mathbf{X}^k, T^k | \mathbf{X}^{k-1}, T^{k-1}) p(\mathbf{X}^{k-1}, T^{k-1} | \mathbf{Z}^{k-1}) \end{aligned} \quad (2-34)$$

量测更新方程使用贝叶斯定理通过新得到的量测 \mathbf{z}^k 更新后验概率密度：

$$p(\mathbf{X}^k, T^k | \mathbf{Z}^k) = \frac{p(\mathbf{z}^k | \mathbf{X}^k, T^k) p(\mathbf{X}^{k-1}, T^{k-1} | \mathbf{Z}^{k-1})}{p(\mathbf{z}^k | \mathbf{Z}^{k-1})} \quad (2-35)$$

其中 $p(\mathbf{z}^k | \mathbf{X}^k, T^k)$ 为量测的似然函数， $p(\mathbf{z}^k | \mathbf{Z}^{k-1})$ 为归一化常数，后验概率密度函数 $p(\mathbf{X}^k, T^k | \mathbf{Z}^k)$ 包含了所有目标的全部状态信息。通过对后验概率密度函数的计算即可对 k 时刻的多目标状态进行估计。从式(2-35)的结果也可以看出，JMPD 模型避免了量测与目标关联的问题。因为贝叶斯框架对整个联合多目标概率密度保持跟踪，所以没有必要识别究竟哪一个目标和哪一个量测是关联的。

2.3.2 多目标系统模型与量测模型

本节在贝叶斯推理框架下阐述具体的目标运动模型和量测模型，选用直角坐标系进行描述。本文讨论的跟踪问题主要关心目标的位置信息 (x, y) 和速度信息 (\dot{x}, \dot{y}) ，所以将目标 t 的描述为四维状态矢量 $\mathbf{x}_t = (x_t, \dot{x}_t, y_t, \dot{y}_t)$ 。在其他场景中，根据具体问题，通过直接扩展状态矢量维度，也可以在目标状态中包括诸如目标识别特征等其他目标特征信息。

本文选取近匀速 (Constant velocity, CV) 模型作为目标运动模型，则目标 t 在 k 时刻的系统模型是

$$\mathbf{x}_t^k = \mathbf{F} \mathbf{x}_t^{k-1} + \mathbf{v}_t^k \quad (2-36)$$

设离散时间间隔为周期 τ ，则目标状态矢量 $\mathbf{x}_t = (x_t, \dot{x}_t, y_t, \dot{y}_t)$ 的状态转移矩阵 \mathbf{F} 可以表示为

$$\mathbf{F} = \begin{pmatrix} 1 & \tau & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & \tau \\ 0 & 0 & 0 & 1 \end{pmatrix} \quad (2-37)$$

\mathbf{v}_t^k 表示加性过程噪声，其协方差矩阵 \mathbf{Q} 为

$$\mathbf{Q} = q_s \cdot \begin{pmatrix} \tau^3/3 & \tau^3/2 & 0 & 0 \\ \tau^2/2 & \tau & 0 & 0 \\ 0 & 0 & \tau^3/3 & \tau^2/2 \\ 0 & 0 & \tau^2/2 & \tau \end{pmatrix} \quad (2-38)$$

其中，过程噪声强度参数 q_s 为噪声功率谱密度。以上的式(2-36)~(2-38)式一同描述了多目标运动模型。

检测前跟踪的研究中，如图 2-4 所示，每一时刻量测为的一帧离散的像素化点迹平面^[31]。分辨单元在 k 时刻获取的值称为 k 时刻的量测。

定义 $\chi_s(\mathbf{x}_t)$ 为分辨单元 s 的指示函数，

$$\chi_s(\mathbf{x}_t^k) = \begin{cases} 1, & \text{目标 } i \text{ 位于分辨单元 } s \\ 0, & \text{else} \end{cases} \quad (2-39)$$

根据这个定义，某时刻存在目标的分辨单元的集合为

$$\psi_x = \{s \mid \chi_s(\mathbf{X}) = 1\} \quad (2-40)$$

假设各分辨单元相互独立，则量测平面似然函数可以表示为所有分辨单元量测似然值的乘积

$$p(z \mid \mathbf{X}) = \prod_s p(z_s \mid \mathbf{X}) \quad (2-41)$$




图 2-4 一帧像素化的量测数据平面

结合式(2-40)，式(2-41)可以进一步写成如下形式

$$\begin{aligned}
 p(z|\mathbf{X}) &= \prod_{s \in \Psi_{\mathbf{x}}} p(z_s|\mathbf{X}) \prod_{s \in \Psi_{\mathbf{x}}} p_0(z_s) \\
 &\propto \prod_{s \in \Psi_{\mathbf{x}}} \frac{p(z_s|\mathbf{X})}{p_0(z_s)}
 \end{aligned} \tag{2-42}$$

其中， $p_0(z_s)$ 表示 $\chi_s(\mathbf{X})=0$ 即无目标存在而仅有背景噪声时分辨单元 s 的量测似然，其分布服从背景噪声的噪声分布。

2.4 算法仿真与性能分析

本节通过2个基本的仿真实验以说明本章给出的SIR粒子滤波算法的有效性。

为了分别评估算法跟踪的可靠性和精确性，本文定义并主要使用以下的两种性能评价指标：目标有效检测概率和位置估计均方根误差。

本文中有效检测一词指的是：当某一时刻目标状态估计与真值之间的距离在一个可接受的位置误差阈值之内时，称该时刻对目标实现了有效检测。本文中跟踪问题通常关注的对目标状态矢量中位置信息的估计。有效检测的定义式表述如下：

$$\delta_{\text{error}} = \|\hat{\mathbf{x}} - \mathbf{x}\|_2 < \Gamma_{\Delta} \tag{2-43}$$

其中， $\|\cdot\|_2$ 表示2-范数， Γ_{Δ} 是最大允许的位置误差阈值。接下来可以使用多次蒙特

卡洛实验来计算目标有效检测的概率。

1) 可靠性评价指标: 目标有效检测概率 (也即多次蒙特卡洛实验的平均有效检测目标数) 用于表征目标跟踪的可靠性, 定义 k 时刻的平均有效检测的目标数目为

$$D^k = \frac{1}{N_M} \sum_{j=1}^{N_M} \sum_{i=1}^T \chi_{\Delta} \left(\left\| \mathbf{p}_{i,j}^k - \hat{\mathbf{p}}_{i,j}^k \right\|_2 \right) \quad (2-44)$$

其中, N_M 是蒙特卡洛实验次数, T 为总目标数, \mathbf{p}_i^k 为第 i 个目标在时刻 k 的真实位置, $\hat{\mathbf{p}}_i^k$ 是对该目标在时刻 k 的状态估计, 指示函数定义为,

$$\chi_{\Delta} \left(\left\| \mathbf{p}_i^k - \hat{\mathbf{p}}_i^k \right\|_2 \right) = \begin{cases} 1, & \left\| \mathbf{p}_i^k - \hat{\mathbf{p}}_i^k \right\|_2 \leq \Gamma_{\Delta} \\ 0, & \text{else} \end{cases} \quad (2-45)$$

则 k 时刻的平均有效检测概率 P_e^k 为

$$P_e^k = D^k / T \quad (2-46)$$

2) 精确性评价指标: 目标的状态估计均方根误差 (Root mean square error, RMSE) 用于表征目标跟踪的精确性, 在本文的目标跟踪问题中, 一般指的是对目标位置估计的均方误差, k 时刻目标位置均方误差定义为

$$RMSE^k = \sqrt{\frac{1}{N_M T} \sum_{j=1}^{N_M} \sum_{i=1}^T \left\| \mathbf{p}_{i,j}^k - \hat{\mathbf{p}}_{i,j}^k \right\|_2^2} \quad (2-47)$$

类似的, 也可以定义在整个跟踪过程中的目标估计 RMSE 值。

仿真实验 1: 通过 ASIR 算法的单目标跟踪验证辅助变量采样的优效性。

仿真参数设置: 设目标为在 X-Y 平面以 CV 模型运动。X-Y 平面可以表示雷达应用中的距离-方位平面或者距离-多普勒平面等, 设 X 和 Y 方向的分辨率为 1m。

目标量测使用理想点模型描述, 即目标仅仅影响其所在的分辨单元, 其余的分辨单元内目标幅值为 0。目标幅度恒定, 其大小由 SNR 和噪声功率共同决定, 其相位在 0 到 2π 间均匀分布。

噪声背景为方差已知的复高斯白噪声。其余仿真参数设置如表 2-2 所示。

图 2-5 所示为信噪比 8dB 下单次蒙特卡洛实验仿真结果。

表 2-2 仿真模型参数设置

目标位置区域	X 方向：0-30m，Y 方向：0-30m
目标初始位置	X 方向：8m，Y 方向：6m
目标初始速度	X 方向：0.56m/s，Y 方向：0.86m/s
加速度噪声功率谱密度	0.015
系统观测时间/目标运动时间	30s（30 帧，帧间间隔 1s）




图 2-5 信噪比为 8dB 时的单次跟踪结果

1) SNR 变化对 SIR 算法单目标跟踪性能的影响。

设粒子总数为 500 个，信噪比设置为从 3~12dB。仿真结果如图 2-6 和图 2-7 所示。

分析图 2-6 中的各帧 RMSE 曲线，可以认为，当信噪比较高（如 SNR=9dB、12dB）时，跟踪精度已经稳定在较高水平，而当信噪比较低时，SNR 增大带来的跟踪精度提升非常明显。图 2-7 也进一步说明了这种变化趋势，随着 SNR 从 3dB 增大到 12dB 的过程中，各帧 RMSE 越来越小，说明跟踪精度越来越好。




图 2-6 不同信噪比下的各帧 RMSE 曲线




图 2-7 不同信噪比下的平均 RMSE

2) 粒子数变化对 SIR 算法对单目标跟踪性能的影响。

设 SNR 为 6dB，粒子数为依次取 $N = 2^i, i = 1, 2, \dots, 10$ ，仿真结果如图 2-8 和图 2-9 所示，注意到由于粒子数规模变动范围较大，为便于观察，横坐标采用了以 2 为底的对数坐标表示。

粒子数约 100 及以上时，才对目标实现了较为可靠的跟踪。而粒子数更少的情况下，跟踪不能有效进行。显然，提高粒子滤波算法检测跟踪能力的最直观办法就是采用更多的粒子数。但是更多的粒子数又将大大增加跟踪系统的计算与存储负

荷，最终导致无法满足工程应用中的实时性要求。为了解决粒子数设定合理性的问题，在本文第四章，提出了一种以对后验估计精度为依据的自适应动态粒子数算法。




图 2-8 信噪比 6dB 时不同粒子数下目标 RMSE 曲线




图 2-9 信噪比 6dB 时不同粒子数下有效检测概率曲线

3) 不同 SNR 下，对比 SIR 算法与 ASIR 算法的单目标跟踪性能。

设粒子总数为 500 个，信噪比设置为从 3~12dB，在同一次蒙特卡洛实验中，分别观察 SIR 算法和 ASIR 算法跟踪性能的变化。各帧的目标位置均方根误差的仿真结果如图 2-10 所示。

首先，无论对于 SIR 算法还是 ASIR 算法，当信噪比降低时，其目标位置均方根误差都会上升，即跟踪精度下降。此外，在信噪比不是很低时，如仿真结果所示

的 12dB 和 9dB 的情况下, 采用 ASIR 算法的跟踪精度总体上比 SIR 算法更高, 但是性能差别不大。随着信噪比逐渐下降, 如在信噪比为 6dB 和 3dB 时, ASIR 算法的跟踪精度表现出优于 SIR 算法的跟踪性能。

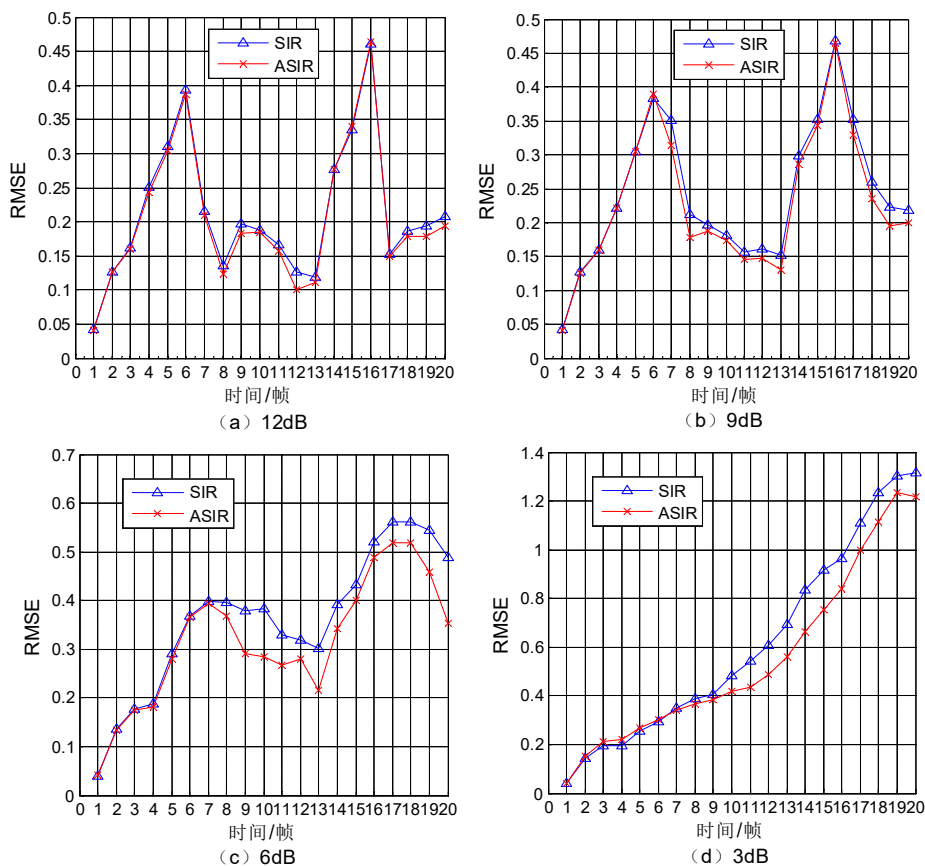


图 2-10 不同 SNR 下, SIR 和 ASIR 的目标位置 RMSE

2.5 本章小结

本章作为第三章和第四章多目标粒子滤波算法的基础, 详细介绍了多目标粒子滤波算法的基本理论以及设计实现的过程。首先, 给出了跟踪问题的状态空间模型与贝叶斯跟踪理论, 它是粒子滤波算法的理论框架。并在此基础上介绍了通过粒子滤波算法实现贝叶斯跟踪的途径, 给出了单目标跟踪的经典 SIR 算法和辅助采样的 ASIR 算法。接着, 研究了一种主流的联合多目标概率密度模型, 在此基础上介绍了多目标运动模型和量测模型。最后用仿真实验对经典的 SIR 算法进行了仿真验证, 说明了粒子滤波算法的有效性, 同时提出了粒子数设定合理化的问题, 本文将在第四章对该问题进行进一步研究; 通过对比 SIR 算法和 ASIR 算法的跟踪性能, 说明设计更优的重要性密度函数是提升算法性能的有效手段。

第三章 基于并行分区状态采样的多目标 PF-TBD 改进算法

第二章介绍的经典 SIR 算法存在众多变体, 辅助粒子滤波算法是其中得到最广泛使用的一种改进形式。在单目标跟踪场景中, 经典 SIR 算法和 APF 算法均使用可接受的粒子数量实现了良好的跟踪性能。然而将它们直接推广到 MTT 场景中, 其算法性能均因维数灾难问题而急剧恶化。

本章首先分析了多目标维数灾难问题, 针对高维度的多目标联合采样困难的问题, 研究了独立分区交叉采样技术, 并介绍了由此衍生出独立分区粒子滤波算法, 指出了其权重计算思路和 2.2.5 小节的辅助粒子滤波的相似之处。接下来, 针对独立分区粒子滤波算法面对临近目标干扰的问题, 在保持其有效的后验概率独立假设的前提下, 提出了基于并行分区状态采样的粒子滤波算法, 通过增加对状态估计的采样, 在计算一阶权重时纳入临近目标影响, 改善目标临近时的跟踪精度。最后通过仿真实验对比验证了提出算法的有效性。

3.1 典型多目标粒子滤波算法

然而, 随着目标增多, 跟踪场景复杂度剧增, 直接将单目标粒子滤波算法推广到 MTT 场景, 存在诸如多目标跟踪的维数灾难、采样所需粒子数过多、计算负荷过大和多目标临近时互相干扰等各种问题。本节主要分析了多目标的维数灾难问题, 有针对性的研究了独立分区交叉采样技术, 并介绍了由此衍生出独立分区粒子滤波算法, 随后也指出了独立分区粒子滤波算法面对的临近目标干扰的困难。

3.1.1 维数灾难问题

在 JMPD 的定义中已提到, 由于目标状态矢量包含多个目标的状态, 首先需要对粒子进行分区处理: 如图 3-1 所示, 将一个粒子划分为多个子分区(partition), 每个子分区对应于一个目标, 保存对该目标的状态采样和相应的权重; 不同的粒子的分区数可能不同, 一个粒子的分区数就是该粒子对监视区域内目标数目的估计。为了区别于单目标场景粒子滤波, 在多目标场景 JMPD 模型中, 粒子称为多目标粒子, 多目标粒子的子分区亦称为“子粒子”(subparticle), 与 2.2.5 节中辅助粒子滤波所权重计算步骤类似的, 赋予子粒子的权重称为一阶权重(first-stage weight), 以区别于多目标粒子的二阶权重(second-stage weight)。




图 3-1 多目标粒子分区示意图

为了通过粒子滤波实现 JMPD 的迭代，一个朴素的想法是，直接利用 JMPD 将 2.2 节展示的单目标 PF-TBD 扩展到多目标场景。与单目标情形类似地，由于式 (2-34) 和式 (2-35) 中的递归估计解析式难以得到，使用一组 N_{part} 个带权重样本来逼近 JMPD $p(\mathbf{x}, T | \mathbf{Z})$ 。

将 T 个目标的多目标的状态矢量写作 $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_{T-1}, \mathbf{x}_T]$ ，则表征 T_p 个目标的粒子 p 的状态矢量为 $\mathbf{X}_p = [\mathbf{x}_{p,1}, \mathbf{x}_{p,2}, \dots, \mathbf{x}_{p,T_p}]$ ，其中， T_p 可以为任意非负整数。记 $\mathbf{x}_{p,j}$ 为粒子 p 的分量 j 。使用 δ_D 表示狄拉克函数，定义为

$$\delta(\mathbf{X} - \mathbf{X}_p) = \begin{cases} 0 & T \neq T_p \\ \delta_D(\mathbf{X} - \mathbf{X}_p) & \text{otherwise} \end{cases} \quad (3-1)$$

那么就可以由一组粒子 \mathbf{X}_p 和其相关权重 w_p 近似逼近 JMPD，

$$p(\mathbf{X}, T | \mathbf{Z}) \approx \sum_{p=1}^{N_{\text{part}}} w_p \delta(\mathbf{X} - \mathbf{X}_p) \quad (3-2)$$

其中 w_p 为归一化权重， $\sum w_p = 1$ 。

利用 JMPD 模型，可以直接将 SIR 算法推广到多目标场景形成 Multitarget-SIR 算法^[3]。然而 Multitarget-SIR 算法存在一个明显的问题，在满足一定的蒙特卡洛数值近似误差要求下，算法复杂程度和所需粒子数随目标数的增加而剧增，即通常所称的多目标“维数灾难”（curse of dimensionality）问题。

对多目标采样的维数灾难问题可以做如下解释：在蒙特卡洛采样中，若用于采样的粒子恰好分布于目标的真实位置附近，则称该粒子采样质量良好或是“优质

的”，因为根据式(2-42)，这些粒子将分配到较高的权重。设一个多目标粒子被划分为 T 个分区（子粒子），对应于此时的 T 个目标，若其中优质子粒子的占比为 p ，则该多目标粒子 T 个分区采样质量都良好的概率为 p^T ；若满足跟踪精度要求的单目标跟踪粒子数为 N_{part} ，那么优质多目标粒子就只有 $N_{part} \times p^T$ ，此时为了达到同等条件下的目标跟踪精度，即需要采样得到的粒子集仍然有 N_p 个优质粒子，粒子数就需要 N_{part}^T ，即所需粒子数随目标数成指数关系增长。

3.1.2 独立分区交叉采样

针对 2.4.1 节指出的多目标跟踪的维数灾难问题，本节给出独立分区（Independent Partition, IP）粒子滤波算法。该算法的基本思路是在计算各个子粒子（分区）的权值后，不同多目标粒子的同一分区之间使用“独立分区交叉采样”，保证多目标粒子每个分区都有较好的状态采样，从而提高多目标粒子的二阶权重。其中，指的是为了提高优质粒子利用率、减少所需的粒子数，对不同多目标粒子同一分区的子粒子按一阶权重进行重采样，剔除采样质量较差的子粒子，保留并复制采样质量较好的子粒子。

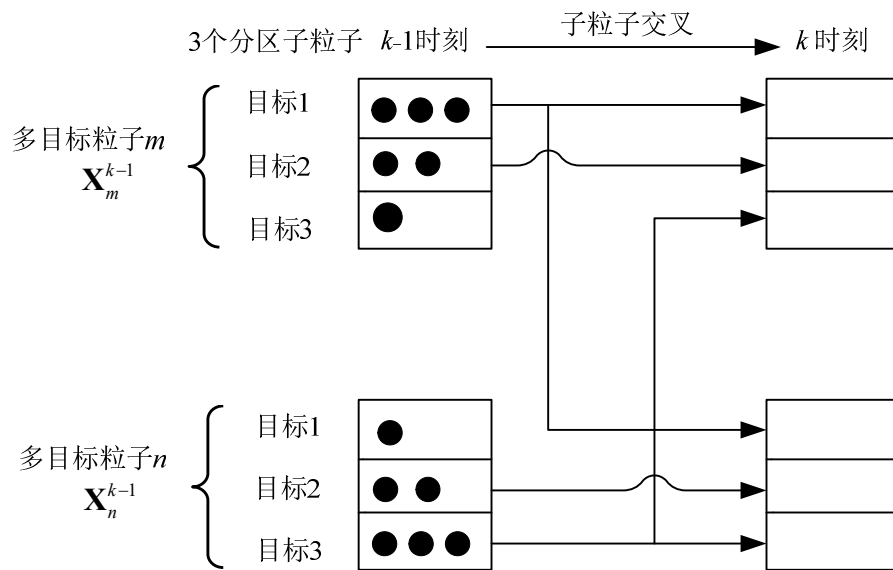


图 3-2 独立分区交叉采样示意图（黑圆点数代表子粒子的一阶权重大小）

独立分区交叉采样技术有以下两层含义：

1) 对各目标独立采样。它利用后验概率独立假设，首先将 JMPD 模型中的多目标粒子划分为多个互相独立的子粒子（分区），每个子粒子对应于一个目标，然后对各个子粒子进行独立采样。

2) 采样时所谓的“子粒子交叉”（subparticle crossover）特点。即 k 时刻不同

多目标粒子的子粒子可能来自 $k-1$ 时刻不同的多目标粒子分区，事实上，经过独立分区采样基于权重的筛选， k 时刻的多目标粒子将由上一时刻拥有较高一阶权重的子粒子组成。图 3-2 即展示一个发生在独立分区交叉采样下的子粒子交叉现象：图中 $k-1$ 时刻存在 3 个目标，第 m 和第 n 个多目标粒子首先被划分为 3 个分区（子粒子），依次对应于 3 个目标，子分区中的黑色圆点表示该子粒子的一阶权重。在 $k-1$ 时刻向 k 时刻的状态转移后， k 时刻第 m 个多目标粒子的第 1 分区和第 2 分区子粒子因权重较高而在交叉采样的筛选中“存活”，它们和第 n 个多目标粒子的第 3 分区子粒子共同组成 $k+1$ 时刻的一个多目标粒子。

现将 IP-PF-TBD 算法流程描述如下：

步骤 1 对每一个目标， $t=1..T_{\max}$ ，通过如下 IP 采样子程序提取子分区 t ：

步骤 1.1 对于每一个粒子 p ， $p=1,...,N_{\text{part}}$ ，利用状态转移函数采样

$$\mathbf{X}_{p,t}^* \sim p(\mathbf{X}_{p,t}^k | \mathbf{X}_{p,t}^{k-1}) \quad (3-3)$$

步骤 1.3 计算子粒子的一阶权重：

$$w_p^k = w_p^{k-1} * p(\mathbf{z} | \mathbf{X}_{p,t}^*) \quad (3-4)$$

步骤 1.4 一阶权重归一化，使 w_p 和为 1， $w_p \leftarrow w_p / \sum_{i=1}^{N_{\text{part}}} w_i$ ；

步骤 1.5 对每一个粒子 p ， $p=1,...,N_{\text{part}}$

a) 从由被 w 定义的分布中重采样得到索引 j

b) 令 $\mathbf{X}_{p,t} = \mathbf{X}_{j,t}^*$

c) 保留一阶权重， $b_{p,t} = w_j$

步骤 2 对于每一个粒子 p ， $p=1,...,N_{\text{part}}$ ，计算二阶权重

$$w_p^k = w_p^{k-1} * \frac{p(\mathbf{z} | \mathbf{X}_p)}{\prod_{t=1}^{T_p} b_{p,t}} \quad (3-5)$$

步骤 3 对多目标粒子进行重采样。

步骤 4 对目标状态进行估计。

3.1.3 临近目标干扰问题

在多个目标彼此分隔较远的情形下，目标相距较远从而其运动和观测生成过程彼此影响甚微，通过假设目标后验概率独立，IP-PF-TBD 将高维空间内的多目标联合采样问题降维处理成若干个单目标的低维问题。此时的 JMPD 可近似分解为多个单目标后验概率的乘积，从而大大简化了计算。这体现了处理多目标跟踪问题

里典型的一种分治法思想。

3.1.2 节研究的采用独立分区交叉采样的 IP-PF 算法就是这种分解处理思路衍生出的一个算法实现。因为当多个目标彼此相对空间距离合适时，IP-PF 算法可以独立地处理各个目标，此时 IP-PF 算法仅需使用跟踪单目标需要的粒子数便可对多目标进行跟踪，在保证跟踪精度的前提下，大幅降低了计算量。然而，IP-PF 算法仅适用于这种目标区隔的情形，当目标彼此靠近时，后验概率独立假设不再存在，IP-PF 算法的前提条件被破坏，此时需要 IP 方法进行适当修正或寻求其他解法。

3.2 并行分区状态采样粒子滤波改进算法

针对 2.4.3 节中看到的 IP-PF 算法难以解决的临近目标干扰问题，本节在 IP-PF 算法的基础上提出基于并行分区状态采样（Parallel partition state-sampling）的粒子滤波算法，以下简称为并行分区粒子滤波算法（Parallel partition particle filter, PP-PF）。PP-PF 算法是 IP-PF 算法的一种改进方法，它保留了 IP 方法中使用的后验概率独立假设，但是通过使用目标状态预测组成多目标似然函数来代替 IP 方法中的单目标似然，在对计算量增加不大的情形下克服了 IP 方法当目标靠近时采样退化问题。

如 3.1.1 节所述，对一组目标进行联合采样的计算负荷会随着目标数增加而呈指数增长。考虑到多目标跟踪所面对的临近目标干扰问题只和一群相互距离足够接近的目标群有关，所以并行分区方法在每次采样前，首先根据空间位置关系将所有目标分为多个相互区隔的群组，即根据各个目标的位置预测信息，将相互临近的目标分成一组考虑。这种动态分组策略有助于进一步提高采样过程的效率。

设在 $k-1$ 时刻有 t_{k-1} 个目标，在第 k 时刻将所有目标分为 r 个群组，记为集合 G_1, G_2, \dots, G_r ，其中 $r \leq t_{k-1}$ 。在这个框架下，可以把独立分区方法看作并行分区方法的特殊情形，即各目标彼此充分远离时，分群后群组数与目标数目相等。对于 k 时刻可能仍然存在的 t_{k-1} 个目标，每个组内元素具独特性，即任一目标必须且仅能属于一个群组，所有群组的并集即为全体目标集合。

$$\bigcup_{i=1}^r G_i = \{1, 2, \dots, t^{k-1}\} \quad (3-6)$$

$$G_s \cap G_l = \emptyset, \{ \forall s, l \in \{1, 2, \dots, r\}, s \neq l \} \quad (3-7)$$

根据目标预测位置进行动态分组的策略是，对于任意一个群组 $s \in \{1, 2, \dots, r\}$ ，组内任一目标 $m \in G_s$ ，若目标 n 满足如下判别关系式

$$\left| \hat{\mathbf{P}}_m^{k|k-1} - \hat{\mathbf{P}}_n^{k|k-1} \right| \leq \Gamma_G \quad (3-8)$$

则 $n \in G_s$, (3-8) 式中, Γ_G 为预设的目标预测分群阈值, $\hat{\mathbf{P}}_m^{k|k-1}$ 表示目标 m 在 k 时刻的预测位置, 目标的预测位置使用状态转移方程计算,

$$\hat{\mathbf{P}}_m^{k|k-1} = \mathbf{A} \mathbf{F} \hat{\mathbf{x}}_m^{k-1} \quad (3-9)$$

其中, $\hat{\mathbf{x}}_m^{k-1}$ 是对第 m 个目标 $k-1$ 时刻的状态估计, \mathbf{F} 为状态转移矩阵, \mathbf{A} 为目标位置信息提取矩阵, 通常对于二维数据平面上目标跟踪问题, 可以写为

$$\mathbf{A} = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{pmatrix} \quad (3-10)$$

当群组划分阈值 Γ_G 足够大时, 对目标分群后的结果与对 k 时刻的所有目标的 JMPD 联合采样的效果相比, 将几乎是一样的, 即此时似然函数满足

$$p(\mathbf{z}^k | \mathbf{X}^k) \approx \lambda \cdot \prod_{l=1}^s p(\mathbf{z}^k | C_l^k) \quad (3-11)$$

其中, λ 为常数, 其大小与目标状态 \mathbf{X}^k 无关; k 时刻量测似然函数 $p(\mathbf{z}^k | C_l^k)$ 仅仅与 C_l^k 有关, 而 C_l^k 表示群 l 中所有目标在 k 时刻的状态。

PP-PF 算法采样的重要性密度函数是

$$p(\mathbf{X}_{i,j}^k | \mathbf{Z}^k) = \prod_{i=1}^{l^{k-1}} b_i(\mathbf{x}_{i,j}^k) p(\mathbf{x}_{i,j}^k | \mathbf{x}_{i,j}^k) \quad (3-12)$$

其中, $b_i(\mathbf{x}_{i,j}^k)$ 被称作一阶权重,

$$\begin{aligned} b_i(\mathbf{x}_{i,j}^k) &\propto p(\mathbf{z}^k | \hat{\mathbf{P}}_1^{k|k-1}, \dots, \hat{\mathbf{P}}_{i-1}^{k|k-1}, \mathbf{x}_{i,j}^k, \hat{\mathbf{P}}_{i+1}^{k|k-1}, \dots, \hat{\mathbf{P}}_{l^{k-1}}^{k|k-1}) \\ &= p(\mathbf{z}^k | \mathbf{x}_{i,j}^k, \hat{\mathbf{C}}_{l-\{i\}}^{k|k-1}) \end{aligned} \quad (3-13)$$

其中, $\hat{\mathbf{C}}_{l-\{i\}}^{k|k-1}$ 表示群 l 中除了目标 i 以外的所有目标的预测位置。

注意到一阶权重计算式 $b_i(\mathbf{x}_{i,j}^k)$ 是 PP-PF 与 IP-PF 两种算法中唯一的不同之处。对于 IP-PF 算法来说, 其一阶权重定义为单目标似然函数

$$b_i(\mathbf{x}_i^k) \propto p(\mathbf{z}^k | \mathbf{x}_i^k) \quad (3-14)$$

使用 IP 或 PP 方法的多目标粒子滤波算法流程如图 3-3 所示。注意到, 并行分

区状态采样方法对 IP 方法的改进仅体现在图中虚线框标示的一阶权值计算上。

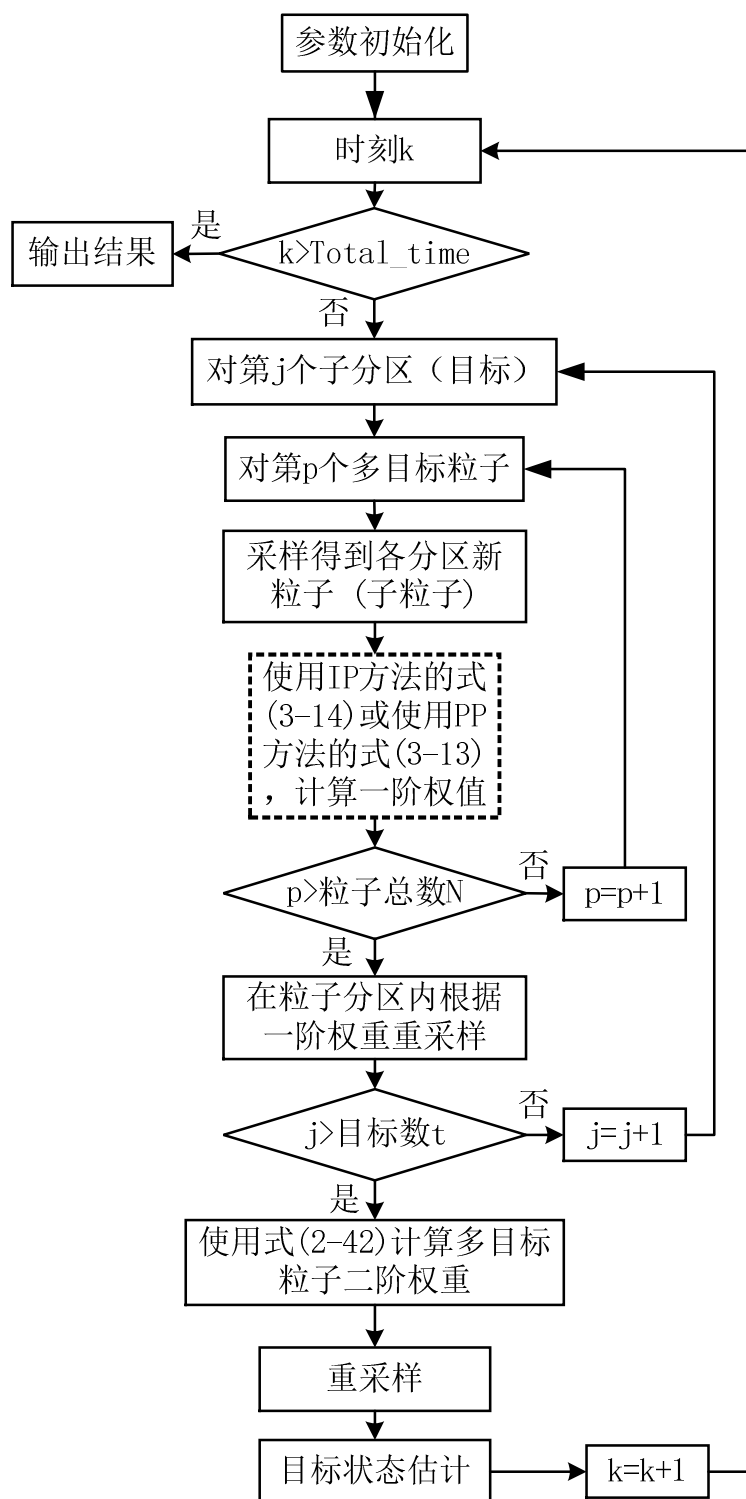


图 3-3 独立分区/并行分区粒子滤波算法流程示意图

这体现了基于并行分区状态采样针对 IP 方法的两点改进：

1) **并行分区**：由于临近目标干扰存在时，IP 方法的目标独立假设不成立，所

以通过预先的分群操作，首先对临近目标干扰问题进行判定，认为分入同一个群组内的目标互为临近目标；

2) **状态采样**：通过在 IP-PF 算法的一阶权重的似然条件中加入除了目标 i 以外群内所有其他目标的预测位置，将临近目标的影响考虑了进来。

此时，二阶权重计算公式为

$$w_j^k \propto \frac{p(\mathbf{z}^k | \mathbf{X}_j^k)}{\prod_{i=1}^{t^{k-1}} b_i(\mathbf{x}_{i,j}^k)} \quad (3-15)$$

3.3 算法仿真与性能分析

本节通过仿真场景验证本章所给出 APF 算法的跟踪性能。

仿真实验 1

仿真目的：研究 3.1.2 节介绍的独立分区粒子滤波算法在无临近目标干扰时的多目标跟踪性能。

仿真场景设置：如图 3-4 为 4 个独立运动目标的航迹图，每个目标的起始位置用 \times 进行标记，在实验中作为先验信息提供给滤波器用于跟踪初始化。监视共持续 20 帧，离散时间采样的帧间隔为 $\tau = 1s$ ，在监视时间内各目标均持续存在。

监视区域设置为 60×60 距离单元的平面，量测平面在 X、Y 方向上的分辨率为 $\Delta x = \Delta y = 1$ ，背景噪声为独立零均值的高斯白噪声，方差 $\sigma_n^2 = 1$ 。

4 个目标均维持近匀速直线运动，其 X、Y 方向上的初始位置和速度参数分别设置如表 3-1 所示，过程噪声功率谱密度为 $q_s = 0.01$ 。目标信噪比依次取值为 3、6、9、12、15dB。采样使用 500 个粒子。蒙特卡洛仿真次数为 500 次。

表 3-1 仿真实验 1 中各目标状态初始化参数

目标标号	1	2	3	4
X 方向位置(m)	10.00	20.00	30.0	40.00
X 方向速度(m/s)	0.60	0.70	0.65	0.70
Y 方向位置(m)	15.00	10.00	12.0	10.00
Y 方向速度(m/s)	1.70	1.40	1.60	1.50




图 3-4 无临近目标干扰的 4 个目标运动场景




图 3-5 不同信噪比下，4 个无临近干扰目标的有效检测概率

在不同信噪比下，对该场景中 4 个独立目标进行跟踪的有效检测概率曲线图如图 3-5 所示，位置估计的 RMSE 曲线如图 3-6 所示。

可以看到目标有效检测概率和位置 RMSE 变化趋势与单目标跟踪场景下的结果几乎一致，且进一步对比观察 2.4 节展示单目标跟踪结果，可见该场景下 IP-PF 对多目标的跟踪相当于对 4 个单目标的跟踪，算法检测跟踪性能良好。这是因为本场景中，4 个目标彼此在空间上维持了良好的区隔状态，目标间的相互影响很弱，满足了 IP-PF 的后验概率独立假设。注意到该仿真仅使用了 500 个粒子进行采样，进一步验证了，理论上当多目标后验独立时，IP-PF 算法可以仅需单目标跟踪的粒

子数规模即可实现相同性能下多目标跟踪。




图 3-6 不同信噪比下，4 个无临近干扰目标的位置估计 RMSE

仿真实验 2:

仿真目的：对比分析 IP-PF 与 PP-PF 对临近目标的检测跟踪性能

仿真场景设置：如图 3-7 和图 3-8 分别为 2 个目标互相区隔（场景 A）和 2 个目标存在临近串扰（场景 B）的运动场景，目标起始位置用×标记。监视共持续 20 帧，离散时间采样的帧间隔为 $\tau=1s$ ，在监视时间内各目标均持续存在。

监视区域设置为 50×50 距离单元的平面，量测平面在 X、Y 方向上的分辨率为 $\Delta x = \Delta y = 1$ ，背景噪声为独立零均值的高斯白噪声，方差 $\sigma_n^2 = 1$ ，

2 个目标均维持近匀速直线运动。图 3-7 所示的场景 A 中，两目标轨迹无交叠；图 3-8 所示的场景 B 中，两目标在约第 10 帧时相互临近。两个场景中的各目标状态初始化参数如表 3-2 所示。过程噪声功率谱密度为 $q_s = 0.01$ 。信噪比依次取值为 3、5、7、9、11、13、15dB。采样使用 500 个粒子。蒙特卡洛仿真次数为 500 次。

表 3-2 仿真实验 2 中各目标状态初始化参数

场景	A		B	
目标标号	1	2	1	2
X 方向位置(m)	10.0	30.0	15.0	35.0
X 方向速度(m/s)	1.0	0.7	1.0	-1.0
Y 方向位置(m)	10.0	10.0	5.0	5.0
Y 方向速度(m/s)	1.2	1.3	1.7	1.5




图 3-7 场景 A：互相区隔的 2 个目标运动轨迹图




图 3-8 场景 B：存在临近串扰的 2 个目标运动轨迹图




图 3-9 不同信噪比下 PP 方法和 IP 方法的跟踪 RMSE 对比




图 3-10 不同信噪比下 PP 方法和 IP 方法的有效检测概率对比

分别采用 IP-PF-TBD 和 PP-PF-TBD 算法处理场景 A 和场景 B, 对比结果如图 3-9 和图 3-10 所示, 图中虚线表示的是场景 A 的仿真结果, 实线表示的是场景 B 的仿真结果。

如同仿真实验 1 所指明的, IP 算法在目标后验独立的场景 A 中依然表现了良好的跟踪性能, 在信噪比约 11dB 时 IP 算法的有效检测概率接近于 1; 但是在场景 B 中, 其性能由于目标临近干扰而恶化, 在信噪比从 3dB~15dB 变化的过程中, 对

比 IP 方法在场景 A 同信噪比下的表现，有效检测概率损失了约 0.1~0.21，在信噪比 15dB 时目标检测概率也仅有约 0.88，RMSE 损失了约 0.9~1.8 个分辨单元。对比 IP 方法在场景 B 中的表现，PP 方法在目标临近时性能提升了约 1.5 至 2.6dB。




图 3-11 场景 B 中各帧交叉采样后存活的子粒子占比

注意到如 3.1.2 节所描述的一样，下一时刻的多目标粒子仅选用一部分当前时刻的子粒子组成，这部分优质粒子权重较高，得以在独立分区交叉采样的筛选中“存活”下来，其余权重较低的子粒子则没有被交叉采样选中而被弃掉，其位置在更新中被复制的优质粒子覆盖。在某一时刻的粒子集中，存活子粒子的数量越多（占比越高），就说明其中采样质量良好的优质粒子越多，进而算法对目标后验概率的近似就越精确。

如图 3-11 即表现了场景 B 下各个时刻交叉采样后存活的子粒子占比变化情况。在第 10 帧之前，IP 与 PP 方法有同样数量的存活子粒子；在第 10 帧之后，由于目标临近串扰的影响，PP 方法中子粒子存活比率更大，相对于 IP 方法始终保持了较高的优质粒子比例，说明基于并行分区状态采样的方法避免了 IP 算法，可以有效处理目标临近影响。

仿真实验 3:

仿真目的：通过一个包含 7 个目标的复杂场景对比 IP-PF 与 PP-PF 算法的多目标跟踪性能。

仿真场景设置：如图 3-12 为包含 7 个目标的航迹图，其中用标记×指示的是

各目标的航迹起始点，目标起始位置和速度信息在仿真中作为先验信息提供给滤波器用于跟踪初始化，各目标在 X、Y 方向上的初始位置与速度参数设定值如表 3-3 所示。整个监视过程形成 50 帧量测，监视区域范围设置为 50×50 的分辨单元，分辨率为 $\Delta x = \Delta y = 1$ ，在整个观测时间中，所有的目标都一直在观测区域中持续运动。

设目标预测分群阈值 $\Gamma = 2$ 。分群结果如图 3-12 所示，各帧最大群中目标数在 1~4 间变化，第 22~23 帧多达 4 个目标处于临近干扰状态。

表 3-3 仿真实验 3 中各目标状态初始化参数

目标标号	1	2	3	4	5	6	7
X 方向位置(m)	12.20	15.40	17.41	16.7	19.95	20.58	29.95
X 方向速度(m/s)	0.26	0.15	-0.07	0.25	0.13	0.21	-0.23
Y 方向位置(m)	12.60	12.10	21.34	41.2	43.13	38.46	41.82
Y 方向速度(m/s)	0.21	0.08	-0.35	-0.21	-0.28	-0.11	-0.18




图 3-12 包含 7 个目标的航迹图




图 3-13 各时刻最大分群中的目标个数

如图 3-14 为信噪比为 6dB 时的各帧平均有效跟踪目标数，可以看到 1~18 帧 IP 方法和 PP 方法均实现了稳健的跟踪，但从第 19 帧开始，IP 方法跟踪效果随目标临近逐渐恶化，无法对目标位置做出有效估计。




图 3-14 信噪比为 6dB 时的平均有效跟踪目标数对比




图 3-15 信噪比为 6dB 时的目标跟踪 RMSE 对比




图 3-16 信噪比为 10dB 时的目标跟踪 RMSE 对比

在信噪比为 6dB 和 10dB 时，IP-PF 和 PP-PF 的 TBD 算法的目标跟踪 RMSE 曲线如图 3-15 和图 3-16 所示。对比不同信噪比下的跟踪 RMSE，可以看到随着信噪比下降，RMSE 均呈现上升趋势。对比同一信噪比下两种算法的跟踪精度，可以看到，基于独立分区采样的 IP-PF 算法在约 23 帧~35 帧时 RMSE 大幅上升，此时正好是跟踪场景中大量出现目标临近干扰的时段，所以跟踪性能急剧恶化，当目标继续运动至互相远离的时刻，IP-PF 的跟踪性能才逐渐恢复正常状态；与之对比，并行分区状态采样的 PP-PF 算法由于在一阶权重计算时，将临近目标的状态估计加入采样的似然函数，从而在很大程度上消除了目标临近对后验概率独立假设的破坏，实现了良好的跟踪效果。

3.4 本章小结

本章首先分析了多目标跟踪的维数灾难问题，研究了独立分区交叉采样技术，并以此为基础，推导了基于 IP 采样的粒子滤波算法。利用后验概率独立假设，该算法先将 JMPD 的高维采样问题进行降维处理，分解为多个单目标跟踪的低维问题。仿真实验说明，当多目标在空间上彼此充分区隔时，仅需使用单目标跟踪所用规模的粒子数目即可实现良好的跟踪效果，其计算量与目标数线性相关。随后，针对 IP 方法无法解决目标临近干扰的问题，在保留其后验概率独立假设的基础上，提出了基于并行分区状态采样的粒子滤波算法，改进了 IP 方法中一阶权重的计算方法，将临近目标影响纳入考虑。通过仿真实验验证了 PP-PF 算法处理临近目标干扰时可以有效提高跟踪精度，进一步分析说明，即使在目标临近干扰存在的情形下，在多目标跟踪的 JMPD 模型中使用后验概率独立假设也可以降低计算量。

第四章 基于 KL 距离的自适应粒子数多目标 PF-TBD 算法

对于粒子滤波算法来说，在每次迭代过程中所有粒子基本都会经历状态转移、权重更新、权重归一化以及重采样等步骤，因此当跟踪过程的粒子数量比较大的时候，算法的计算总量就会很大。在传统粒子滤波算法中，采样所用的粒子数是固定的，但为了保证跟踪精度通常会人为预设一个较大的数值。

本章针对粒子数的合理设置问题做出研究，首先引入 KL 距离或称 KL 散度（Kullback-Leibler distance/divergence, KLD）的基本理论，目的是藉此来衡量先验分布和目标真实后验分布函数的差异，然后将其应用于粒子滤波采样粒子数设置中，推导出以后验分布估计精度为依据的粒子数计算公式，随后将这一结论运用于多目标 PP-PF-TBD 算法中，最后通过仿真实验验证了对粒子数的自适应调节性能。

4.1 基于 KL 距离的粒子数自适应设定

作为影响粒子滤波计算量和跟踪精度的重要参数，通常希望能在保证算法跟踪精度的条件下选择尽量少的粒子数。理想的动态粒子数算法能够在粒子分布相对集中、估计确定性较高时，使用较少的粒子；而在粒子分布相对分散、估计不确定性较高时，使用更多的粒子。本章中引入的基于 KL 距离采样的粒子滤波算法即具备这样的自适应设定采样规模的能力。

基于 KL 距离采样的自适应粒子滤波算法的核心思想是：以对真实后验概率密度的估计精度为依据，在每次迭代中，确定采样至少所需用的粒子（样本）数目，使得目标的真实后验概率密度和以采样样本近似的概率密度之间的差异以置信度为 $1-\delta$ 的概率小于误差 ε 。

为了便于推导近似误差的界限，设目标的真实后验概率密度函数是一个分段的离散分布函数，例如离散分布树或多维柱状图^[32]。以下将展示如何使用 KL 距离来描述两个分布 p 与 q 之间的差异，并用其性质来决定粒子采样的粒子数。

4.1.1 KL 距离基本理论

为了描述两个概率密度函数之间的差异大小，本节引入 KL 距离作为度量工具。KL 距离（亦被称为 KL 散度、信息差、相对熵）是一种常用于表征两个概率分布差异的函数，该函数的具体定义可用如下方式表述：

对离散空间上的两个概率分布 p 和 q ，定义从 q 到 p 的 KL 距离是

$$KLD(p, q) = \sum_x p(x) \log \frac{p(x)}{q(x)} \quad (4-1)$$

类似的，对于连续空间上的两个概率分布 p 和 q 而言，从 q 到 p 的 KLD 定义为

$$KLD(p, q) = \int_x p(x) \log \frac{p(x)}{q(x)} dx \quad (4-2)$$

根据式(4-1)和式(4-2)定义可知 KL 距离具有以下的基本数学性质：

- 1) 非负性： $KLD(p, q) \geq 0$
- 2) 当且仅当 p 与 q 几乎处处同分布时，有 $KLD(p, q) = 0$
- 3) 非对称性：KL 距离是两个概率分布 p 和 q 差别的非对称性的度量，由 KL 距离的定义可得， $KLD(p, q) \neq KLD(q, p)$

在信息论里，对 KL 距离的另一种表述是：使用基于 q 的编码对来自 p 的样本进行编码时平均所需的额外的位元数。典型应用场景下， p 表示数据的真实分布， q 表示数据的理论分布、模型分布或 p 的近似分布^[46]。

4.1.2 引入 KL 距离估计后验估计精度

设一个函数服从 m 点离散分布，将状态空间划分为 m 个子空间，对该分布采样 N_{KL} 个样本（粒子），令矢量 \bar{N} 表示从每个离散子空间中采样的样本数， $\bar{N} = (N_1, N_2, \dots, N_m)$ ，即

$$N_{KL} = \sum_{j=1}^m N_j \quad (4-3)$$

\bar{N} 服从多项分布， $\bar{N} \sim \text{Multinomial}_m(N_{KL}, \bar{p})$ ，其中 $\bar{p} = (p_1, p_2, \dots, p_m)$ 表示每个离散点的真实概率，真实概率 \bar{p} 在 N_{KL} 个样本采样下的样本极大似然估计(MLE) $\hat{\bar{p}}$ 是

$$\hat{\bar{p}} = N_{KL}^{-1} \bar{N} \quad (4-4)$$

则对 \bar{p} 的似然比统计量 $\log \lambda_n$ 为

$$\log \lambda_n = \sum_{j=1}^m N_j \log \left(\frac{\hat{p}_j}{p_j} \right) \quad (4-5)$$

由式(4-4)，各离散子空间采样数可表示为

$$N_j = N_{KL} \hat{p}_j, \quad j = 1, \dots, m \quad (4-6)$$

代入公式(4-5)，可得

$$\log \lambda_n = N_{KL} \cdot \sum_{j=1}^m \hat{p}_j \log \left(\frac{\hat{p}_j}{p_j} \right) \quad (4-7)$$

对比离散分布 KL 距离的定义式(4-1)和式(4-7)，可以看出统计量 $\log \lambda_n$ 为真实概率分布的 MLE 到真实分布的 KL 距离的 N_{KL} 倍，即

$$\log \lambda_n = N_{KL} \cdot KLD(\hat{p}, \bar{q}) \quad (4-8)$$

当采样数 N_{KL} 趋于无穷大时，似然比统计量 $\log \lambda_n$ 收敛到一个自由度为 $m-1$ 的卡方分布，即

$$\text{当 } N_{KL} \rightarrow \infty \text{ 时, } 2 \log \lambda_n \rightarrow \chi_{m-1}^2 \quad (4-9)$$

令 $P_p(KLD(\hat{p}, \bar{q}) \leq \varepsilon)$ 表示采样近似的密度与目标真实后验概率密度之间的 KL 距离小于的误差上界 ε 概率。则该概率与粒子滤波采样所用的粒子数的关系可以由式(4-8)如下推得

$$\begin{aligned} P_p(KLD(\hat{p}, \bar{q}) \leq \varepsilon) &= P_p(2N_{KL} KLD(\hat{p}, \bar{q}) \leq 2N_{KL} \varepsilon) \\ &= P_p(2 \log \lambda_n \leq 2N_{KL} \varepsilon) \\ &= P(\chi_{m-1}^2 \leq 2N_{KL} \varepsilon) \end{aligned} \quad (4-10)$$

卡方分布的分位数如下：

$$P(\chi_{m-1}^2 \leq \chi_{m-1, 1-\delta}^2) = 1 - \delta \quad (4-11)$$

倘若选择采样所用的粒子数目 N_{KL} 使得 $2N_{KL} \varepsilon = \chi_{m-1, 1-\delta}^2$ ，联立式(4-10)和式(4-11)，可以推得，

$$P_p(KLD(\hat{p}, \bar{q}) \leq \varepsilon) = 1 - \delta \quad (4-12)$$

经过上述推导，采样所需粒子数目和采样近似的精度之间的关系已经很明显了。在采样时如若选择如下的粒子数

$$N_{KL} = \frac{1}{2\varepsilon} \chi_{m-1, 1-\delta}^2 \quad (4-13)$$

即可实现目标，使采样近似概率密度和目标真实后验概率密度之间的差异以置信度为 $1-\delta$ 的概率小于 ε 。

由于(4-13)式要求在每次对新粒子采样时都需要即时地重新计算一遍，在实际操作中，为了减少计算量，需要对采样粒子数给出一个便于计算的近似解。Johnson 等学者在 1994 年出版的专著[45]中给出了一个 $\chi^2_{k-1,1-\delta}$ 良好的近似解，称为 Wilson-Hilferty 转换，则最低采样粒子数可以近似计算为

$$N_{KL} = \frac{1}{2\varepsilon} \chi^2_{m-1,1-\delta} \approx \frac{m-1}{2\varepsilon} \cdot \left(1 - \frac{2}{9(m-1)} + \sqrt{\frac{2}{9(m-1)}} \cdot u_{1-\delta} \right)^3 \quad (4-14)$$

其中 $u_{1-\delta}$ 是标准正态分布 $N(0,1)$ 的上 $1-\delta$ 分位数；对于一个 δ 的特殊值，查标准对照表即可得到相应的 $u_{1-\delta}$ 的值。公式(4-14)说明采样所需的粒子数与误差上界的倒数成正比，与自由度 m 成一阶线性关系。在 4.2 节的仿真实验中，对基于 KL 距离的变粒子数采样（KLD-sampling）策略的预设参数进一步进行了灵敏性分析。

4.1.3 基于 KL 距离变粒子数采样的 PP-PF 算法设计与流程

结合 3.2 节的 PP-PF 算法，本节将式(4-14)给出的变粒子数结论应用在多目标粒子滤波算法中，提出基于 KLD 变粒子数采样的 PP-PF 算法。应用(4-14)式结论面临的主要困难和矛盾在于，真实的后验概率密度原本是粒子滤波器最终意图估计的未知值，而为了估计采样所需的粒子数，又要求已知此后验概率（或至少得到一个对真实后验概率较好的近似）。

针对这个后验概率未知的问题，采取的解决方案依然是 2.2 节介绍过的粒子滤波的基本思想，用加权粒子表征的先验概率代替目标真实概率密度函数^[35]。对于给定的 KLD 误差上界 ε 和分位数 $1-\delta$ ，仅需确定其离散分布的子空间数 m ，即可代入式(4-14)计算最低采样粒子数。

在基于 KLD 方法的粒子采样过程中，使用辅助变量对每个目标进行采样。目标后验概率密度可表示为

$$p(\mathbf{X}^{k+1}, \mathbf{a} | \mathbf{Z}^{k+1}) \propto p(\mathbf{Z}^{k+1} | \mathbf{X}^{k+1}) \prod_{j=1}^l p(\mathbf{x}_j^{k+1} | \mathbf{x}_{j,a_j}^k) \quad (4-15)$$

其中，辅助变量为 $\mathbf{a} = [a_1, a_2, \dots, a_l]^T$ ， a_j 表示根据先验信息从第 k 时刻筛选优质粒子的序号去采样 $k-1$ 时刻第 j 个目标的状态。这种先预测再回溯的辅助采样思想在 2.2.5 小节的 APF 算法中已经介绍过，在本章的高维问题中依然得到了体现。

设从重要性函数 $q(\cdot)$ 中采样得到 \mathbf{x}_j^{k+1} ，辅助变量 $\mathbf{a}_i = [a_1^i, a_2^i, \dots, a_{c_i}^i]^T$ ，对于 $i = 1, 2, \dots, N_{part}$ ，更新阶段的权重计算表达式如下

$$w_i^{k+1} \propto \frac{p(\mathbf{z}^{k+1} | \mathbf{X}_i^{k+1}) \prod_{j=1}^t p(\mathbf{x}_{j,i}^{k+1} | \mathbf{x}_{j,a_j}^k)}{q(\mathbf{X}_i^{k+1}, \mathbf{a}_i | \mathbf{Z}^{k+1})} \quad (4-16)$$

在下面给出 KLD-PF 算法流程中，可以发现，KLD-sampling 策略并非在已知子空间数 m 并计算出最低采样规模后再开始采样，而是先开始对粒子逐个进行采样操作，逐次迭代子空间数 m ，并利用式(4-14)更新最小采样粒子数，在对所有粒子完成采样前，并不能确定粒子数目，当采样粒子数 N_l 逐步增加至 N_{KL} 时，触发其停止采样条件，即停止采样。

算法输入包括目标在第 k 时刻的后验概率密度函数， $\{\mathbf{X}_i^k, w_i^k | i = 1, 2, \dots, N^k\}$ ，KL 距离的误差上界 ε ，置信度参数 δ ，子空间单元大小 Δ_{bin} ，采样粒子数下界 N_{min} ，算法实现步骤如下：

步骤 1 根据 k 时刻目标状态对每个目标 $k+1$ 时刻位置信息进行预测，并基于预测的位置信息将所有目标按其空间关系划分入不同的群组。

步骤 2 根据步骤 1 结果，对目标分组进行处理。分组处理的子流程如下：

步骤 2.1 初始化：

设 \mathbf{P}^{k+1} 用于记录粒子状态， N_l 表示群 l 内已经采样的 N_l 个粒子， N_{KL} 表示采样所需粒子数目， m 表示非空的子空间数， α 表示到当前采样粒子的未归一化权重之和。初始化令 $\mathbf{P}^{k+1} = \emptyset$ ，另外 4 个参数置零， $N_l = 0, N_{KL} = 0, m = 0, \alpha = 0$ 。

步骤 2.2 在一个 do-while 循环中进行采样：

do

步骤 2.2.1 已采样的粒子数自增 1：

$$N_l = N_l + 1 \quad (4-17)$$

步骤 2.2.2 引入辅助变量采样：

$$\mathbf{a}_l = [a_1, a_2, \dots, a_{c_l}] \quad (4-18)$$

其中 c_l 表示第 l 个群中的目标数。

步骤 2.2.3 分别对每个目标的当前粒子进行状态转移：

$$\mathbf{x}_{j,N_l}^{k+1} \sim p(\mathbf{x}_j^{k+1} | \mathbf{x}_{j,a_j}^{k+1}), j = 1, 2, \dots, c_l \quad (4-19)$$

步骤 2.2.4 计算权重：

$$\tilde{w}_{c_l, N_l}^{k+1} = p(\mathbf{z}^{k+1} | \mathbf{C}_{l, N_l}^{k+1}) \quad (4-20)$$

其中 $\mathbf{C}_{l, N_l}^{k+1}$ 为群 l 中所有目标的第 N_{KL} 个粒子的状态。

步骤 2.2.5 计算未归一化权重和 α :

$$\alpha = \alpha + \tilde{w}_{c_l, N_l}^{k+1} \quad (4-21)$$

步骤 2.2.6 记录粒子采样位置信息:

$$\mathbf{P}^{k+1} = \mathbf{P}^{k+1} \cup \{\mathbf{C}_{l, N_l}^{k+1}\} \quad (4-22)$$

步骤 2.2.7 判断目标 $\mathbf{C}_{l, N_l}^{k+1}$ 的采样位置是否落入空子集 b , 并以递增的方式确定非空子集数 m : 即如果目标 $\mathbf{C}_{l, N_l}^{k+1}$ 的采样位置落入空子集 b , 标记该子空间 b 状态为非空, 并使非空子集数自增 1:

$$m = m + 1 \quad (4-23)$$

根据公式(4-14), 代入此时的更新采样所需的粒子数目 N_{KL} 。

while ($N_l < N_{KL} \parallel N_l < N_{\min}$)

也即当 $N_l = N_{KL}$ 时跳出循环, 结束采样。

步骤 2.3 计算归一化的权重:

$$\tilde{w}_{c_l, i}^{k+1} = \tilde{w}_{c_l, i}^{k+1} / \alpha, \text{ 其中 } i = 1, 2, \dots, N_l \quad (4-24)$$

步骤 3 取停止采样时粒子数 N_l 的最大值, 得到采样所需的粒子数:

$$N^{k+1} = \max \{N_l, l = 1, 2, \dots, s^k\} \quad (4-25)$$

其中 s^k 表示 k 时刻分群数目。

步骤 4 在每一个目标群组内进行重采样。

步骤 5 计算粒子 \mathbf{X}_i^{k+1} 的权重:

$$\tilde{w}_i^{k+1} \propto p(\mathbf{z}^{k+1} | \mathbf{X}_i^{k+1}), \quad i = 1, 2, \dots, N^{k+1} \quad (4-26)$$

步骤 6 权重归一化:

$$\tilde{w}_i^{k+1} = \tilde{w}_i^{k+1} / \sum_{n=1}^{N^{k+1}} \tilde{w}_n^{k+1} \quad (4-27)$$

步骤 7 粒子重采样过程, 得到 $k+1$ 时刻的粒子状态以及对应的权重

$$\{\mathbf{X}_i^{k+1}, w_i^{k+1} \mid i=1,2,\dots,N^{k+1}\}$$

步骤 8 估计目标状态。

KLD-sampling-PF 算法实现的具体步骤如上。从步骤 2.2.7 中可以看出, KLD 定义的采样规模 N_{KL} 是否更新取决于采样的粒子落入了一个新的空子集还是已经采样过的子空间。在每次采样结束后, 将当前非空子集数 m 代入式(4-14)的结论计算所需粒子数 N_{KL} 。对已采样粒子数 N_l 和所需粒子数 N_{KL} 之间影响变化的过程, 可以这样描述: 在采样之初, 由于大部分子空间都是尚未被采样过的空集, 几乎每次新粒子采样都很有可能落入一个空子集中, 使得非空子空间数 m 不断增长, m 增加的同时会不断更新所需粒子数 N_{KL} , 使停止采样条件 N_{KL} 也不断提高; 然而随着采样持续进行, 越来越多的子空间被标记为非空, 非空子集数量 m 逐渐变得仅偶尔会增加, 但是采样粒子数 N_l 依然随着采样而自增, 最终采样的粒子数目 N_l 会达到 N_{KL} , 此时采样停止。值得注意的是, 虽然采样过程是在粒子数未预先设定的情况下先开始的, 并不会无休止地进行下去, 因为给定任意一个子空间大小 Δ_{bin} , 子空间 m 的最大数量是有限的, 随着 N_{KL} 不断自增, 采样停止条件必然会被触发。

4.2 算法仿真与性能分析

本节通过仿真实验验证 KLD-PF-TBD 算法的检测跟踪性能与对粒子数量的自适应调节能力

仿真实验 1

仿真目的: 分析 KLD-sampling 方法中影响粒子数设置的 3 个预设参数的灵敏性, 即设置不同的 KL 距离误差上界 ε 、置信度 $1-\delta$ 和离散分布的子空间单元大小 Δ_{bin} 对算法性能的影响。

仿真场景设置: 为了体现 KLD-sampling 预设参数对算法性能的影响, 在一个简单的单目标运动场景下进行实验。监视共持续 50 帧, 离散时间采样的帧间隔为 $\tau=1s$, 在观察时间内目标持续在视域内运动。监视区域设置为 60×60 距离单元的平面, 量测平面在 X、Y 方向上的分辨率为 $\Delta x=\Delta y=1m$, 背景噪声为独立零均值的高斯白噪声, 噪声方差 $\sigma_n^2=1$ 。

目标维持近匀速直线运动, 其 X、Y 方向上的初始位置和速度参数分别设置为 $[10,0.6,15,1.7]$, 过程噪声功率谱密度为 $q_s=0.01$ 。信噪比取值为 10dB, 初始粒子数 500 个, 蒙特卡洛仿真次数为 500 次。

1) KL 距离的误差界限 ε 的设置的灵敏性分析。

设定置信度参数 $\delta=0.01$, KL 距离误差上界取值为 0.5~0.005。仿真结果如图 4-1 和图 4-2 所示。

如图 4-1(a)所示,随着 KL 距离误差上界从 0.005 放松至 0.5, 目标跟踪 RMSE 逐渐从 0.14 增大至 0.37。图 4-1 (b) 展示了目标有效检测概率的变化趋势, 在误差上界为 0.5 时, 有效检测概率为 0.46, 随着误差界限逐渐收紧, 有效检测概率迅速升高, 当误差上界收紧至 0.05 时, 有效检测概率已经逼近 1。




图 4-1 误差界限 ε 对算法性能的影响 (a) RMSE 曲线; (b) 有效检测概率曲线




图 4-2 不同误差上界 ε 下采样所用平均粒子数对比

图 4-2 的结果进一步验证了式(4-16)中粒子数 N_{KL} 与误差上界的负相关性, 由于本次仿真实验使用了高信噪比下的单目标跟踪场景, 在允许误差界限为 0.5 的宽

松条件下, KLD-sampling 在第二帧即迅速将采样规模缩小至约 50 个粒子。在误差上界为 0.01 时, 平均采样粒子数在初始值 500 上下浮动。

2) 分析置信度 $1-\delta$ 的设置灵敏性分析。

设 KL 距离误差上界为 $\varepsilon = 0.01$, 置信度参数 δ 取值为 0.01~0.2。仿真结果如图 4-3 和图 4-4 所示。

从图 4-3 可以看出, RMSE 与置信度参数 δ 正相关, 有效检测概率与置信度参数 δ 负相关。当 $\delta=0.2$, 即目标真实后验与采样近似分布的差异以置信度 80% 的概率小于误差 0.01 时, RMSE 约为 0.28, 当 $\delta=0.1$, 即置信度为 90% 时, RMSE 约为 0.24。当 $\delta=0.01$, 即置信度为 99% 时, RMSE 减小至约 0.17。与之相反, 有效检测概率随着置信度参数的增大而减小, 在 $\delta=0.2$ 时, 有效检测概率约为 0.9, 当 $\delta=0.01$ 时, 有效检测概率约为 1。总的来说, 在本次仿真中置信参数所取的 0.01~0.2 范围内, 算法检测跟踪性能变化不大。另外, 在图 4-4 中, KL-sampling 决定的平均粒子数与置信度 $1-\delta$ 正相关, 随着置信度从 0.8 升高至 0.99, KL-sampling 的平均粒子数从约 30 增加至约 90。但是总的来说, 相比与改变误差界限带来的巨大变化, 算法性能对置信度参数的敏感度仍然要低得多。





图 4-3 置信度 $1-\delta$ 对算法性能的影响 (a) RMSE 曲线; (b) 有效检测概率曲线

图 4-4 不同置信度 $1-\delta$ 下采样所用平均粒子数

3) 分析离散分布子空间单元大小 Δ_{bin} 的设置的灵敏性分析。

设定 KL 距离误差上界 $\varepsilon = 0.01$ ，置信度参数 $\delta = 0.01$ 。 Δ_{bin} 设为 0.5, 1, 1.5 三个值，仿真结果如图 4-5 和图 4-6。由于有效检测概率均 1，故不在此画出。

从仿真结果中可以看出，位置 RMSE 与 Δ_{bin} 具有一定的正相关性，平均粒子数与 Δ_{bin} 具有一定的负相关性，但是在误差界限与置信度一定的情形下， Δ_{bin} 的不同取值对算法性能影响很小。

综上所述，跟踪性能对误差上界 ε 的灵敏性最高，较小的误差上界较小时，目标的检测性能会提升，但跟踪所用的粒子数增多，对系统提出了更高的计算与存储能力要求。因而 KLD-sampling 策略需要选取合适的误差上界以实现算法性能和计算量上的平衡。另外，跟踪性能对离散分布子空间单元大小 Δ_{bin} 灵敏性最低，故算法中可以将子空间分布单元设置地较大。




图 4-5 不同子空间单元大小 Δ 下的平均采样粒子数




图 4-6 不同子空间单元大小 Δ 下的 RMSE 曲线

仿真实验 2

仿真目的：通过一个包含 7 个目标的复杂运动场景验证 KLD-PP-PF 算法的优越性。

本次仿真实验使用和 3.3 节的仿真实验 3 相同的仿真场景，包含 7 个目标的航迹轨迹图如图 3-12 所示。分群门限为 $\Gamma_G=2$ ，初始粒子数设为 500 个。

如图 4-7 和图 4-8 是在信噪比 6dB 和 10dB 时，KLD-PP-PF 和 KLD-IP-PF 算

法平均跟踪粒子数对比。随着目标临近，KLD-PP-PF 算法所用粒子数随着临近目标相互影响而增加，在第 35 帧后，随着目标临近干扰的减弱，KLD-PP-PF 采样所用的粒子数又逐渐降低至约 700 个，表现出 KLD-PP-PF 算法对采样规模的自适应调整能力。除此之外，对比图 4-7 和图 4-8，可以看出 KLD 选择的粒子数也与目标的信噪比有关，粒子数会随着信噪比的增加而减少。




图 4-7 信噪比 6dB 时平均跟踪所用粒子数




图 4-8 信噪比 10dB 时平均跟踪所用粒子数

注意到图 4-7 和图 4-8 中，KLD-IP-PF 的粒子数在第 1 帧至第 5 帧从初始的

500 个粒子增加到 1000 个后,但是第 5 帧至第 50 帧的粒子数变化并不明显,说明 IP 方法基本不具备 KLD-sampling 策略下粒子规模的自适应调整能力。




图 4-9 信噪比 6dB 下平均有效跟踪目标数对比

如图 4-9 对比了 6dB 下四种算法的平均有效跟踪目标数。一方面,使用 PP 方法采样的粒子滤波算法在处理临近目标干扰时表现了较高的稳定性,而 IP 方法则无法对目标临近场景进行可靠的跟踪;另一方面,KLD-sampling 策略给 IP 和 PP 方法均带来了一定性能提升,且对 PP 方法的提升更为明显。

如图 4-10 为信噪比 6dB 下 KLD-IP-PF 和 KLD-PP-PF 目标跟踪的 RMSE 对比。一方面,针对临近目标干扰的典型场景的处理,PP 方法相比与 IP 方法体现了巨大的优越性;另一方面,在 IP 和 PP 方法上采用 KLD-sampling 策略,均在一定程度上提升了目标有效检测能力,其中,如同图 4-7 和图 4-8 结果已经展示的,KLD-PP-PF 具有显著强于 KLD-IP-PF 的自适应调节能力,显然在 PP 方法上采用 KLD-sampling 策略对算法性能的提升更明显。




图 4-10 信噪比为 6dB 时目标跟踪 RMSE 对比

进一步地，表 4-1 和表 4-2 对使用固定粒子数和采用 KLD 变粒子数的 IP-PF 和 PP-PF 算法进行对比。其中，IP-PF 与 PP-PF 的采样规模分别设置为与使用了 KLD-sampling 策略的平均粒子数相同，仿真程序运行的软硬件环境为：MATLAB R2013b，3.30GHz 的 Intel Core i5-4590 CPU 上，内存 8.00GB。表中统计的是各算法完成一次蒙特卡洛实验的平均运行时间。

表 4-1 信噪比 6dB 下算法性能对比

	采样粒子数	检测概率	RMSE	单次运行时间/s
KLD-IP-PF	平均 1116	0.781	0.461	69.5
KLD-PP-PF	平均 948	0.935	0.290	79.9
IP-PF	固定 1116	0.771	0.496	65.4
PP-PF	固定 948	0.927	0.313	71.1

对比两表中不同信噪比下的各算法性能，可以看出在采用 IP 方法时，由于独立采样计算负荷低，因此运行时间最短，但是无论是 IP-PF 还是 KLD-IP-PF 均无法胜任对临近目标的检测跟踪，当信噪比从 6dB 增加至 10dB 时，可以看到 KLD-sampling 策略并没有大幅下调所需粒子数；相较之下，KLD-PP-PF 不仅可以解决目标临近问题，也具备很强的粒子数自适应调整能力，在信噪比 6dB 升高至 10dB

的场景中，所用平均粒子规模缩减了将近 30%，且相比使用同规模固定粒子数的 PP-PF 表现出更优的检测跟踪性能。

表 4-2 信噪比 10dB 下算法性能对比

	采样粒子数	检测概率	RMSE	单次运行时间/s
KLD-IP-PF	平均 985	0.812	0.451	61.3
KLD-PP-PF	平均 669	0.968	0.268	58.3
IP-PF	固定 985	0.801	0.471	57.6
PP-PF	固定 669	0.945	0.286	54.8

4.3 本章小结

本章针对粒子数的合理设置问题做出研究，首先通过引入 KL 距离衡量先验分布和目标真实后验分布函数的差异，然后将其应用于粒子滤波采样所需粒子数设置中，给出了以对后验分布估计精度为依据的粒子数计算公式，随后将这一结论运用于多目标 PP-PF 算法中，提出了 KLD-PP-PF 算法。通过对 KLD-sampling 策略 3 个预设参数的灵敏性分析表明，算法对误差上界 ε 的灵敏性最强：当误差上界较大时，目标跟踪 RMSE 较高，有效检测概率较低，但采样所用的粒子数少，计算量小；当误差上界变小时，目标跟踪性能会提升，但跟踪所需的粒子数增多。故 KLD-sampling 策略在设置合适的误差上界时需要再算法性能和计算符合间取舍。另外，算法对离散分布子空间单元大小 Δ_{bin} 的灵敏性最弱，故算法中可以选取适当的子空间分布单元。最后通过仿真实验验证了 KLD-PP-PF 算法较强的粒子数调节能力，在一个信噪比从 6dB 升至 10dB 的典型场景中，该算法采样的平均粒子数自适应地减少了近 30%，同时检测跟踪性能优于使用同规模固定粒子数的 PP-PF 算法。

第五章 无源声呐水声目标 PF-TBD 处理方案及性能验证

无源声呐（或被动声呐）系统指的是自身不主动发射声波，而是通过被动接收目标的辐射噪声测定目标方位的水下探测系统。本章针对无源声呐检测前跟踪应用的实际问题，分析了用于 TBD 的无源声呐信号模型、方位历程图的背景均衡、目标的航迹起始与终止方法，利用本文提出的多目标粒子滤波检测前跟踪算法对两批某型无源声呐实测数据进行了离线处理，并对处理结果进行性能分析，验证了本文提出的多目标粒子滤波检测前跟踪算法的有效性。

5.1 无源声呐水声目标的 PF-TBD 处理方案

无源声呐系统限于被动接收目标辐射信号，无法计算和目标的距离。因此无源声呐系统中多采用纯方位跟踪方法来对目标进行跟踪。在实际处理中，首先需要从采集的原始目标辐射信号里获取关于目标方位的量测信息，首先经过合适的预处理步骤，形成所需的 TBD 数据平面。本文使用常规波束形成（Conventional Beamforming, CBF）算法来处理原始宽带接收信号^[47-48]，并组合各时刻得到的空间谱信息，形成方位历程图，最后使用本文提出的多目标粒子滤波 TBD 算法对水声目标实现了 TBD 处理。本章采用的水声目标 PF-TBD 处理方案如图 5-1 所示，本节主要介绍水声信号预处理过程，将在虚线框内的多目标粒子滤波算法部分。

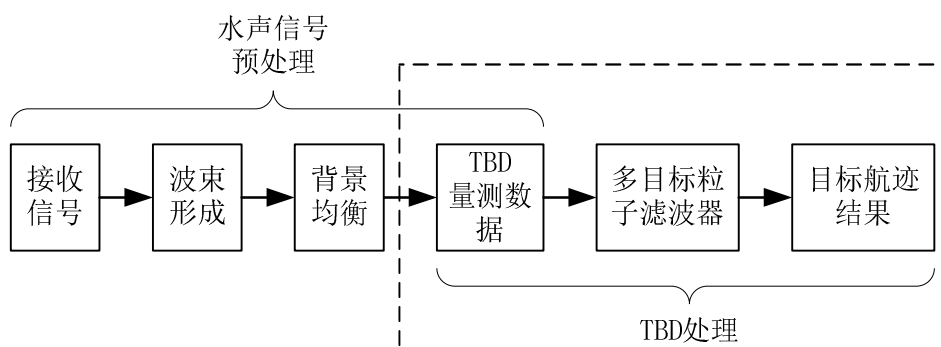


图 5-1 无源声呐水声目标的 PF-TBD 处理方案流程示意图

5.1.1 无源声呐系统接收信号模型

无源声呐信号所接收的水下辐射噪声主要包括：舰船机械设备噪声，螺旋桨水动力噪声、和其他海洋环境噪声等^[49]。信号的具体形式是未知的，无源声呐系统接收工作频段内所有噪声信号。舰船辐射噪声可以根据其特征分为：线谱、连续谱

和混合谱。本文选用连续谱噪声作为无源声呐系统的信号源。

假设目标辐射噪声是一个远场信号

$$\tilde{s}(t) = s(t)e^{j\omega t} \quad (5-1)$$

其中， ω 是目标回波的角频率， $s(t) = u(t)e^{j\gamma(t)}$ 是回波 $\tilde{s}(t)$ 的复包络， $u(t)$ 和 $\gamma(t)$ 分别为目标回波的幅度和相位。该信号由 M 个阵元的水听器阵列接收，设第一个阵元接收到的信号是

$$\tilde{x}(t) = \tilde{s}(t) = s(t)e^{j\omega t} \quad (5-2)$$

那么第 m 个阵元接收到的信号就可以写成

$$\tilde{x}_m(t) = \tilde{x}(t - \tau_m) = \tilde{s}(t - \tau_m) \quad (5-3)$$

假设在时域上信号慢变化，可做如下的近似，

$$s(t) \approx s(t - \tau_m) \quad (5-4)$$

那么，第 m 个阵元接收到的信号可以简化为

$$\tilde{x}_m(t) = \tilde{s}(t - \tau_m) = s(t - \tau_m)e^{j\omega(t - \tau_m)} \approx s(t)e^{j\omega t}e^{-j\omega\tau_m} \quad (5-5)$$

$$\tilde{x}_m(t) = \tilde{s}(t)e^{-j\omega\tau_m} \quad (5-6)$$

将 m 个阵元接收到的信号写成矢量形式，

$$\tilde{\mathbf{x}}(t) = \mathbf{a}(\theta)\tilde{s}(t) = \mathbf{a}(\theta)s(t)e^{j\omega t} \quad (5-7)$$

其中，信号矢量表示为 $\tilde{\mathbf{x}}(t) = [\tilde{x}_1(t) \ \tilde{x}_2(t) \ \cdots \ \tilde{x}_M(t)]^T$ ；方向矢量表示为 $\mathbf{a}(\theta) = [1 \ e^{-j\omega\tau_2} \ \cdots \ e^{-j\omega\tau_M}]^T$ 。

复载波 $e^{j\omega_0 t}$ 一般不携带回波的信息，因此在进行空间谱估计时，仅考虑复基带信号，上式的离散形式课表示为（单个入射信号）

$$\mathbf{x}(n) = \mathbf{a}(\theta)s(n) \quad (5-8)$$




图 5-2 均匀线阵示意图

对于 M 个阵元组成的均匀线阵，如图 5-2 所示，时间差 $\tau_m = m \cdot \tau$ ， τ 是相邻两个阵元接收信号的时间差。设相邻阵元间的波程差为 $d \sin \theta$ ，则时间差 τ_m 与波程差的关系如下

$$\tau_m = \frac{md \sin \theta}{p} \quad (5-9)$$

其中， p 表示信号的速度，对于水声声呐系统，速度应取本区当前水域的声速。

由公式 $\omega = 2\pi / \lambda$ ，阵列的方向矢量可表示为

$$\mathbf{a}(\theta) = [1 \quad e^{-j\phi} \quad \dots \quad e^{-j(M-1)\phi}]^T, \quad \phi = 2\pi d \sin \theta / \lambda \quad (5-10)$$

其中， λ 是载波波长。

对于多个目标的多个信号，接收信号的离散形式为

$$\mathbf{x}(n) = \mathbf{A}\mathbf{s}(n) + \mathbf{v}(n) \quad (5-11)$$

其中信号方向矩阵 \mathbf{A} 为

$$\begin{aligned} \mathbf{A} &= [\mathbf{a}(\theta_1) \quad \mathbf{a}(\theta_2) \quad \dots \quad \mathbf{a}(\theta_L)] \\ &= \begin{bmatrix} 1 & 1 & \dots & 1 \\ e^{-j\omega\tau_2} & e^{-j\omega_2\tau_2} & \dots & e^{-j\omega_L\tau_2} \\ \vdots & \vdots & \ddots & \vdots \\ e^{-j\omega\tau_M} & e^{-j\omega_2\tau_M} & \dots & e^{-j\omega_L\tau_M} \end{bmatrix} \end{aligned} \quad (5-12)$$

其中， \mathbf{A} 是方向矩阵； $\mathbf{v}(n)$ 为加性噪声^[50-51]。

5.1.2 接收信号的波束形成方法与方位历程图

文献[55]在对比了不同的 DOA 方法后,综合考虑算法实现的效率和性能,选用如下的 CBF (Conventional Beamforming) 算法对无源声呐的接收信号进行波束形成得到关于方位的空间谱信息。

在接收到的阵列信号后,波束形成器的输出信号可由接收信号的加权和表示

$$y(t) = \mathbf{w}^H \mathbf{x}(t) \quad (5-13)$$

其中, $y(t)$ 表示输出信号, $\mathbf{w} \in \mathbb{C}^{M \times 1}$ 是权值矢量, $\mathbf{x}(t) = [x_1(t) \ x_2(t) \ \cdots \ x_M(t)]^T$ 为接收信号矢量。输出信号功率表示为

$$P = E \left\{ |y(t)|^2 \right\} = \mathbf{w}^H E \left\{ \mathbf{x}(t) \mathbf{x}^H(t) \right\} \mathbf{w} = \mathbf{w}^H \mathbf{R} \mathbf{w} \quad (5-14)$$

其中, \mathbf{R} 是空间相关矩阵。

改变入射角 θ , 代入 $\mathbf{w} = \mathbf{a}(\theta)$ 计算后可以得到一系列的权值, 遍历视域内所有的角度就可以获得输出功率关于角度的函数, 称为空间谱

$$\psi_{CBF}(\theta) = \mathbf{a}^H(\theta) \mathbf{R} \mathbf{a}(\theta) \quad (5-15)$$

该空间谱即为的单一时刻的量测值, 获得多个连续时刻的空间谱后, 可以将其组合生成了目标角度状态量测随时间演化的平面图, 该图像称为方位历程图。理论上该量测信息即可直接提供给 TBD 模块进行处理。在实际运用中, 空间相关矩阵可通过 N 次快拍的离散信号 $\mathbf{x}(n), n=1, 2, \dots, N$ 计算得到

$$\hat{\mathbf{R}} = \frac{1}{N} \sum_{n=1}^N \mathbf{x}(n) \mathbf{x}^H(n) \quad (5-16)$$

5.1.3 无源声呐水声目标的系统模型和量测模型

本章中无源声呐水声目标的状态信息为纯方位角信息, 为此, 有必要对第二章 2.3 节所述的系统模型和量测模型进行重新叙述。

无源声呐水声目标的系统模型仍以式(2-36)表示, 其中令 $\mathbf{x}_t = (\theta_t, \dot{\theta}_t)$ 表示无源声呐目标 t 的二维状态矢量, θ_t 表示其方位角, $\dot{\theta}_t$ 表示其方位角速度。与此对应地, 式(2-37)和式(2-38)依次可重新写为

$$\mathbf{F} = \begin{pmatrix} 1 & \tau \\ 0 & 1 \end{pmatrix} \quad (5-17)$$

$$\mathbf{Q} = q_s \cdot \begin{pmatrix} \tau^3 / 3 & \tau^2 / 2 \\ \tau^2 / 2 & \tau \end{pmatrix} \quad (5-18)$$

系统量测模型为一维纯方位角信息， k 时刻量测信息按声呐各方位分辨单元划分为 $\mathbf{z}^k = (z_1^k \ z_2^k \ \dots \ z_M^k)$ ，其中 $z_m^k, m=1,2,\dots,M$ 表示 k 时刻第 m 个分辨单元的方位角量测信息。

量测模型对应的量测似然函数仍以式(2-42)表示为

$$p(\mathbf{z}^k | \mathbf{X}^k) \propto \prod_{m \in \mathcal{Y}_k} \frac{p(z_m^k | \mathbf{X}^k)}{p_0(z_m)} \quad (5-19)$$

本章待处理的方位数据共 361 个分辨单元，即 $1 \leq m \leq 361$ ，实际声呐系统监视的角度范围为 $-90^\circ < \theta \leq 90^\circ$ ，角度分辨率为 0.5° 。分辨单元标号与实际的目标方位角换算关系为

$$m = \text{ceil}(2\theta) + 181 \quad (5-20)$$

其中， ceil 函数表示向正无穷方向取整。

5.1.4 方位历程图的背景均衡处理

理论上，TBD 处理不需要如同传统 DBT 方法对原始量测进行门限处理。但是在实际工程应用中，方位历程图受噪声干扰明显，若不对噪声进行预处理直接显示，则每一时刻，整个量测区域均是航迹起始的可疑目标，需要进行全局搜索与计算，不仅会大大增加航迹起始的计算量，影响序贯处理的实时性，更重要的是，方位历程图上很多杂乱的谱线，会影响 TBD 算法对目标航迹的起始性能，可能带来过多更多虚假航迹。

针对这个问题，本文采用的方案是，利用文献[52]基于中值滤波的排序截断平均（Order Truncate Average, OTA）背景均衡算法对方位历程图进行杂波抑制，预先筛选可疑目标。该算法可以减少噪声干扰，改善方位历程图显示效果，使方位历程图中目标和背景噪声的区别更加明显。背景均衡算法不仅使目标显示更加清晰，还提升了检测前跟踪算法目标起始的性能^[52-53]。

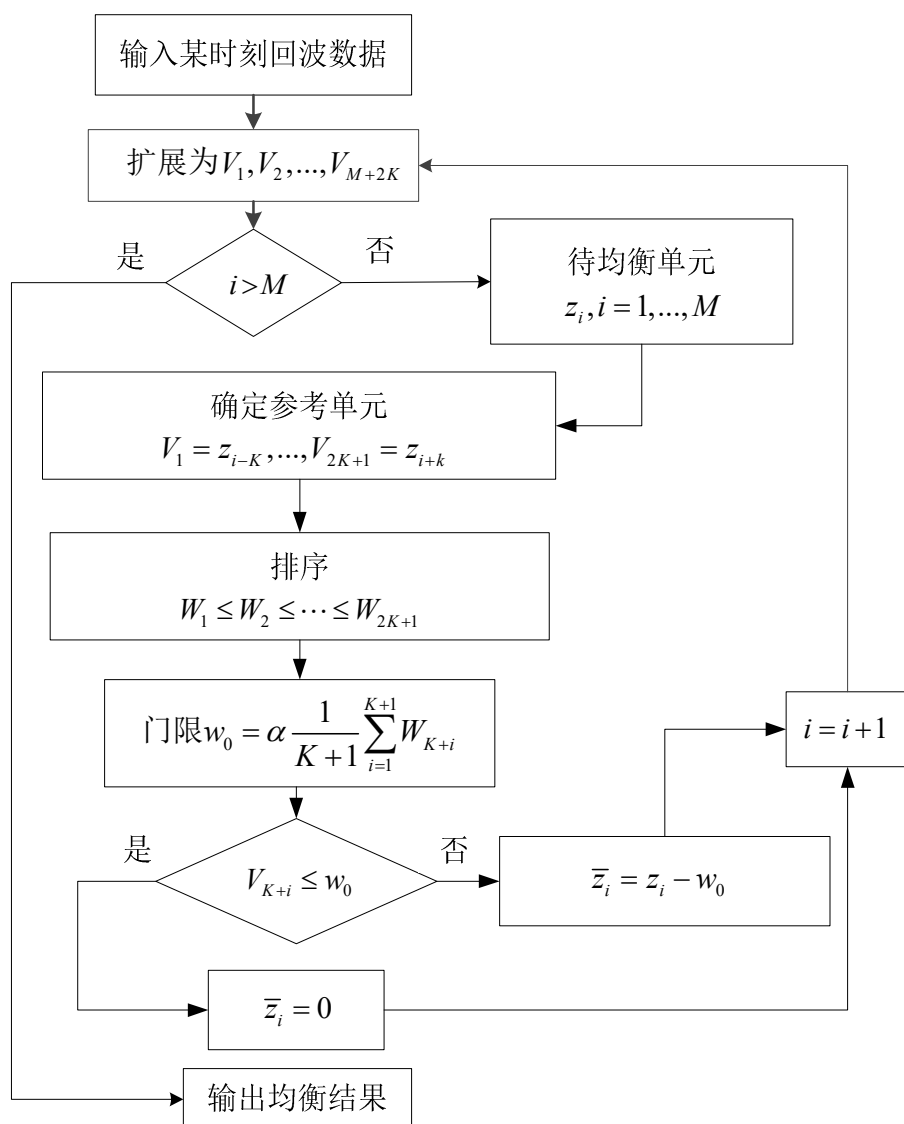


图 5-3 基于中值滤波的 OTA 背景均衡算法流程

基于中值滤波的 OTA 背景均衡算法的具体步骤如下。令 z_1, \dots, z_M 表示某一时刻的 M 个分辨单元的回波数据（也即方位历程图中的一行）：

步骤 1 数据扩展：将回波数据序列 z_1, \dots, z_M 向两侧扩展为

$$z_{K+1}, \dots, z_2, z_1, \dots, z_M, z_{M-1}, \dots, z_{M-K} \quad (5-21)$$

将扩展后的数据重新表示为： $V_1, V_2, \dots, V_{M+2K}$ 。

步骤 2 确定参考单元：根据参考窗长度及待均衡单元确定参考单元范围，假设待均衡单元为 $z_i, i = 1, \dots, M$ ，参考窗长度为 $2K+1$ ，则选定参考单元为

$$V_1 = z_{i-K}, \dots, V_{2K+1} = z_{i+k} \quad (5-22)$$

步骤 3 确定参考门限：将步骤 2 中得到的序列 V 按数值大小重新排序得到序列 W ：

$$W_1 \leq W_2 \leq \dots \leq W_{2K+1} \quad (5-23)$$

设置序列中值拒收门限：

$$w_0 = \alpha \frac{1}{K+1} \sum_{i=1}^{K+1} W_{K+i} \quad (5-24)$$

其中 α 为拒收门限因子。

步骤 4 对待均衡单元进行中值滤波，修正方位历程数据：将 $V_{K+i}, i=1, \dots, M$ 与步骤 3 中计算的门限进行比较

$$\bar{z}_i = \begin{cases} 0, & V_{K+i} < w_0 \\ z_i - w_0, & otherwise \end{cases} \quad (5-25)$$

得到经过背景均衡处理后的一组新数据表示为： $\bar{z}_i, i=1, \dots, M$

从上述算法的流程描述中可以看出，通过选取合适的窗长参数 K 和拒收门限因子 α ，可以设定合适的拒收门限，得到所需的均衡结果^[55]。在 5.1.5 节中，这种便宜实现的中值滤波方法将被应用于目标航迹起始阶段，实现对可疑目标的筛选。

5.1.5 目标航迹起始与终止

粒子滤波算法通常默认假设初始时刻的目标的先验状态已知，然后根据贝叶斯推理框架依次递推运算。在前文的仿真实验中，目标初始状态都是以先验的形式给出的。但在实际工程运用中，目标的初始状态一般是未知的，并且某些目标可能在检测时间内提前消失。即实际应用中面临的场景往往是目标数时变且未知，因此将粒子滤波算法应用在检测前跟踪算法时，需要加入目标起始和终止的判断。

粒子滤波检测前跟踪算法以带权重的粒子来表征目标的后验概率密度，并且以粒子的状态采样和权值来估计目标的状态。当前分辨单元中目标存在的粒子权值和分辨单元中目标不存在而仅有噪声时的粒子权值具有明显的差异，且信噪比越高，差异越明显。利用粒子权值的这种特性，本文选择使用文献[54]提出的一种利用多帧粒子权值和门限判决的方式实现对目标进行航迹起始和终止的方法。

利用粒子权值判断目标航迹起始与终止的方法可以表述如下：

1) 目标航迹起始阶段：先使用 5.1.4 节的背景均衡算法对方位历程图进行处

理，经过了门限的量测均作为新的可疑目标。

对每个存在了 N_l 帧的目标，计算这 N_l 帧的所有粒子的权值和 Σ_w ，然后与设置好的权值门限 Γ_w 对比，若 $\Sigma_w < \Lambda$ 则判断为虚假目标不予起始，删除这 N_l 帧的状态估计。

2) 目标航迹终止阶段：与目标起始的方法相同，对于已经起始的每个目标联合 N_l 帧，计算权值和 Σ_w 与门限 Λ 对比，若 $\Sigma_w < \Lambda$ 则终止该目标航迹并删除这 N_l 帧的状态估计。

事实上，无论是对可以目标的筛选判决还是对上一时刻目标持续的判决过程军备转化为粒子权值之和的门限判决。而联合多帧判决则能大大减少对某些时刻较强杂波的虚警和对弱目标的漏检，提高了算法检测性能。

本文的 TBD 处理中，设连续帧数 $N_l=3$ ，包含目标航迹起始与终止的算法流程示意图如图 5-4 所示。

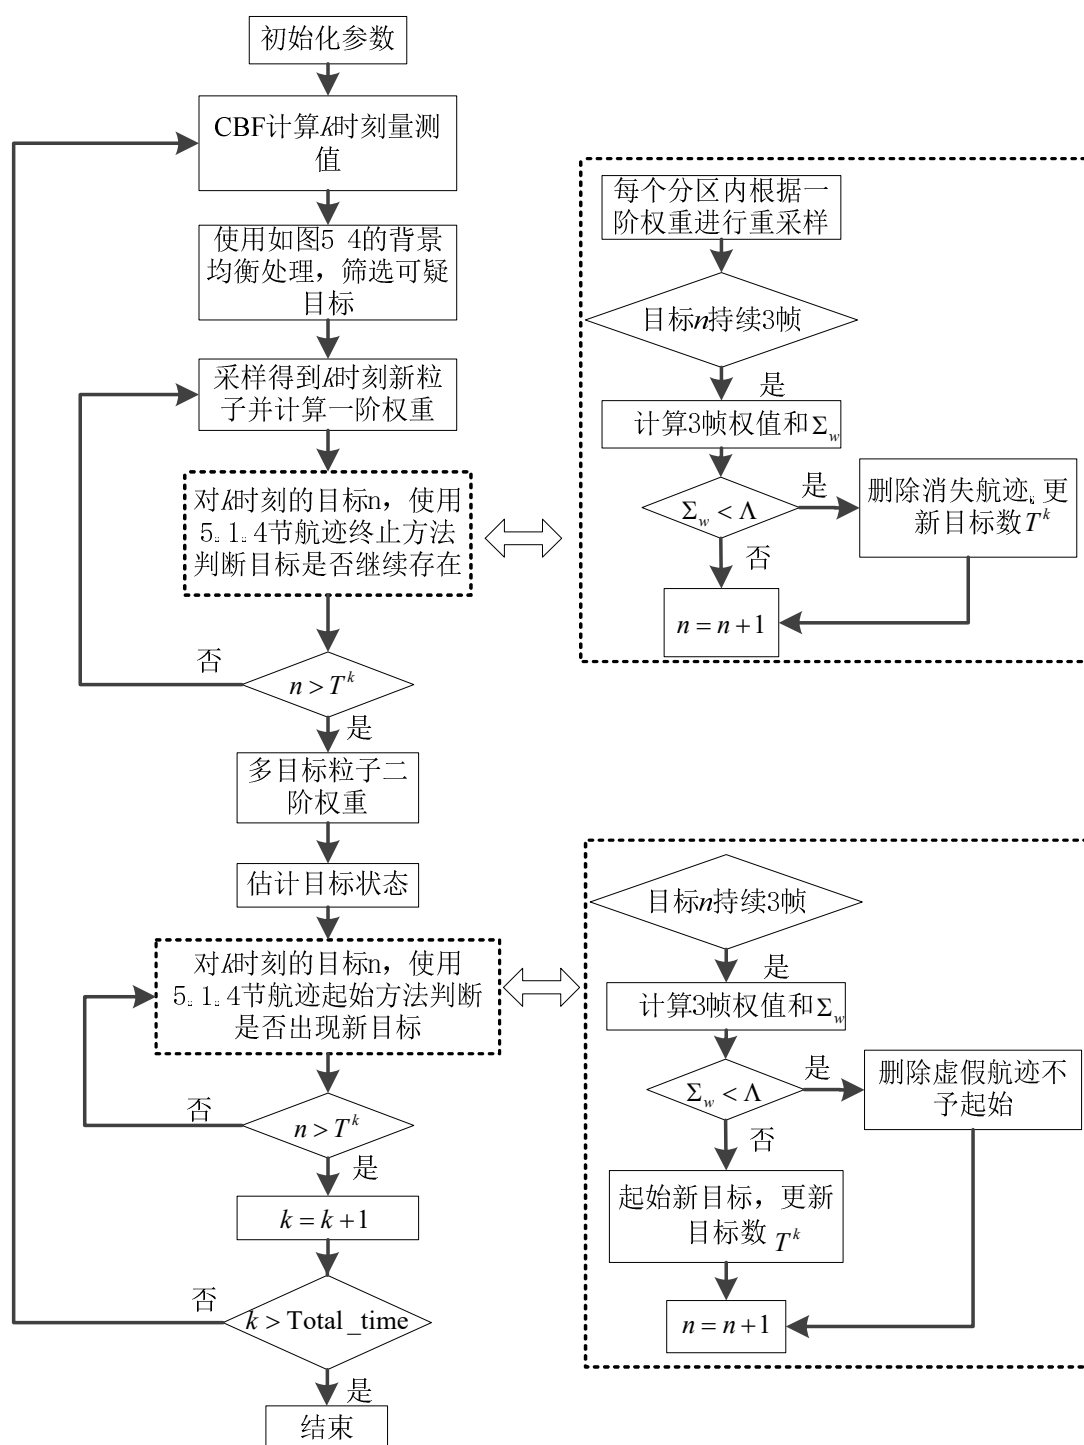


图 5-4 包含目标航迹起始与终止的算法流程示意图

5.2 无源声呐水声目标 PF-TBD 算法实测数据处理

在 5.1 节中通过对于本节利用前文提出的多目标 PF-TBD 算法对 2 批无源声呐

实测数据分别进行了离线处理。

5.2.1 第一批实测数据处理

第一批实测数据的方位历程图如图 5-5，主要有一下特性：

- 1) 该监视区域内共有 7 个目标，其中呈周期显示的目标 1 为主动信号目标，该目标，其余 6 个目标在方位历程图中为连续显示；
- 2) 方位历程图左侧边沿可见来自声呐拖船本身的高幅值噪声，在 TBD 处理中通过分区域处理的办法消除了这部分噪声干扰。
- 3) 方位历程图右下角可见两个扩展的目标 6 和目标 7，其航迹在约 100 时刻至 200 时刻间发生了交叠。





图 5-5 第一批实测数据方位历程图

对本批数据进行背景均衡处理，窗长参数 $k=13$ ，门限参数 $\alpha=1$ 。背景均衡结果图 5-6 所示。可以看出，方位历程图经过背景均衡算法处理，成片的噪声基本被去除，目标显示清晰。最右侧两个目标由于信噪比相对较低和波束扩展的影响也丢失了部分信息。

图 5-6 第一批实测数据背景均衡处理结果 ($k=13$, $\alpha=1$)

考虑到目标航迹独立性较强, 信噪比较高, 适合采用目标后验概率独立假设进行独立采样; 另外, 在第四章的仿真结果已经表明, KLD-sampling 策略对 IP-PF 算法性能提升有限, 且会增加额外计算复杂度, 故对第一批实测数据选择 IP-PF-TBD 进行处理。

航迹终止判决帧数为 $N_t=3$, 处理结果如图 5-7 所示。




图 5-7 第一批实测数据 IP-PF-TBD 算法处理结果

5.2.2 第二批实测数据处理

第二批实测数据的方位历程图如图 5-8 所示。

该批数据主要有以下特性：

- 1) 左侧目标 1 和目标 2 的信号幅值最高，且其运动表现了一定的机动目标特性，目标 3~5 都是匀速运动。
- 2) 目标 3 信号幅值随着时间推移逐渐减弱，在约第 100 时刻与目标 1 发生航迹交叉。
- 3) 在方位历程图约 55° ，在 90 时刻处，目标 4 和目标 5 航迹发生交叉，且交叉结束后，目标 4 的信号幅值较低，其航迹末端出现了一定的波束扩展。




图 5-8 第二批实测数据方位历程图

对本批数据进行背景均衡处理处理：窗长参数 $k = 10$ ，门限参数 $\alpha = 1$ ：均衡处理结果如图 5-9 所示。参数设置合适保证了每个细节处的可疑目标信息都被保留。




图 5-9 第二批实测数据背景均衡结果

首先选择使用第三章介绍的 IP-PF-TBD 算法对图 5-9 的结果进行处理, 初始粒子数 500 个, 终止判决帧数为 $N_t = 3$, 得到的一次处理结果如图 5-10 所示。从图 5-10 中可以看到, 目标 3 消失后, TBD 算法及时终止了该目标的跟踪航迹; 而对于目标 1 和 2 则及时起始了航迹进行跟踪。

然而, 对该结果进一步分析, 也可以看到 IP-PF 算法易受临近目标干扰的特点:

1) 在第 90 时刻附近, 目标 4 在和目标 5 发生航迹交叉后, 信噪比较弱的目标 4 受到目标 5 的临近串扰, 如图 5-11 局部图所示目标 4 航迹已经偏离进入目标 5 航迹中。直到第 116 时刻, 目标 4 航迹才在方位角 64° 位置被重新起始。

2) 在第 100 时刻附近, 目标 3 航迹发生轻微偏离。

对图 5-10 的处理结果的分析可以看出, 总体上符合 IP 方法对独立目标跟踪性能良好, 对临近目标抗干扰性能差的特性。




图 5-10 第二批实测数据 IP-PF-TBD 处理结果




图 5-11 IP-PF-TBD 处理结果局部图（目标 4 航迹断裂）




图 5-12 多目标 PF-TBD 算法处理结果

选择使用本文第四章提出的 KLD-PP-PF-TBD 算法对第二批数据进行重新处理。设置初始粒子数 500 个, KLD 误差上界 $\varepsilon = 0.05$, 置信度 $1 - \delta = 0.99$, 子空间单元大小 $\Delta_{\text{bin}} = 1^\circ$ 。处理结果如图 5-12 所示。可以看到目标 4、5 的交叉航迹得到了很好的处理, 目标 3 航迹末端避免了错误地向较强的目标 1、2 的方向偏离。表 5-1 进一步对比了两种算法的处理结果, 由于本批数据中目标信噪比较高, KLD-PP-PF-TBD 算法很好地利用了 KLD-sampling 策略进行动态粒子数调整, 仅使用很少的粒子规模即实现了本批数据的 TBD 处理, 大大降低了计算量。

表 5-1 第二批实测数据处理方案对比

处理算法	IP-PF-TBD	KLD-PP-PF-TBD
跟踪所用粒子数	固定 500	初始 500, 平均 147
运行时间/s	168.7	98.6
航迹处理结果	目标 3 航迹偏离, 目标 4 航迹断裂	航迹完整度良好

5.3 本章小结

本章针对实际无源声呐系统亟待处理的多目标检测跟踪问题, 研究了适用于 TBD 的无源声呐信号模型、目标起始与终止方法和方位历程图的背景均衡处理。随后利用 PF-TBD 算法实现了对两批某型无源声呐实测数据的离线处理, 针对两批实测目标不同的特性, 选择使用 IP-PF-TBD 算法处理第一批独立性较强的目标, 选择 KLD-PP-PF-TBD 算法处理第二批包括交叉航迹的临近目标。实测处理结果充分验证了本文所提出的算法的有效性和工程实用价值。

第六章 结束语

6.1 全文总结

本文主要针对多目标的粒子滤波算法，研究了该算法中多目标场景所导致的维数灾难问题以及典型场景下的临近目标干扰问题，对独立分区粒子滤波算法进行改进，提出了基于并行分区状态采样的粒子滤波算法，并针对粒子数合理化设定问题，设计了用于多目标 TBD 的 KLD-PP-PF 算法。主要研究工作概括如下：

1、针对多目标跟踪的维数灾难问题，研究了独立分区交叉采样技术，该采样方法通过子粒子交叉大幅提高粒子采样效率；并在此基础上研究了 IP-PF 算法，该算法通过将高维度的多目标联合采样降维成为多个单目标采样，使得计算量与目标数线性相关，大大降低了计算量。第一批水声目标实测数据处理结果验证了 IP-PF-TBD 在处理强后验独立性的目标场景时具有显著优势。

2、针对 IP-PF 算法无法解决的目标临近干扰的问题，提出了基于并行分区状态采样的粒子滤波算法。在保持 IP 方法后验独立假设的前提下，通过增加对状态估计的采样，改进了一阶权重的计算方法，将临近目标影响纳入考虑，从而提高了跟踪精度。仿真实验表明，在典型的多目标场景下（包含相互临近目标），IP-PF 的算法性能在目标临近时出现了急剧恶化，而基于并行分区状态采样的 PP-PF 算法实现了较好的跟踪效果，很大程度上消除了临近目标对后验概率独立假设的破坏。

3、针对粒子滤波预设固定粒子数的问题，提出多目标的 KLD-PP-PF 算法。该算法基于一种 KL 距离的自适应粒子数粒子设置方法，通过先验概率和后验概率分布的差异大小自适应地决定粒子数的多少，同时 KLD-PP-PF 保持了独立分区交叉采样的降维采样特点，并能利用并行分区状态采样处理目标临近干扰的影响，达到了减少计算量的目的。对 KLD-sampling 策略的 3 个预设参数进行的灵敏性分析表明，跟踪性能对误差上界 ϵ 的灵敏性最高，较小的误差上界较小时，目标的检测性能会提升，但跟踪所用的粒子数增多。因而 KLD-sampling 策略需要选取合适的误差上界以实现算法性能和计算量上的平衡。另外，跟踪性能对离散分布子空间单元大小 Δ_{bin} 灵敏性最低，故算法中可以将子空间分布单元设置地较大。最后通过仿真实验验证了 KLD-PP-PF 算法的粒子数自适应调节能力，在一个信噪比从 6dB 升至 10dB 的典型场景中，该算法采样的平均粒子数自适应地减少了近 30%，同时检测跟踪性能优于使用同规模固定粒子数的 PP-PF 算法。

4、针对无源声呐多目标检测跟踪问题，研究了多目标粒子滤波 TBD 的工程实现方案，使用本文提出的多目标 PF-TBD 算法对某型无源声呐的 2 批实测数据进

行了离线处理。针对第一批目标独立性较强的数据，采用 IP-PF-TBD 算法实现高效的处理；针对第二批存在多处目标临近干扰的数据，IP-PF-TBD 的处理结果出现了航迹偏移和航迹断裂，随后采用本文提出的 KLD-PP-PF-TBD 算法避免了临近目标干扰，其航迹完整度明显优于 IP-PF-TBD 的处理结果，此外，相较使用同样初始粒子规模的 IP-PF-TBD 算法，KLD-PP-PF-TBD 算法通过自适应调节粒子数，减少了约 40% 的处理时间，验证了本文提出的多目标 PF-TBD 算法的在典型跟踪场景下的优效性。

6.2 工作展望

本文针对多目标场景下的粒子滤波 TBD 算法，重点关注于如何有效控制多目标 PF-TBD 的计算量，在本文基础上可以进一步探讨的问题包括：

（1）研究基于其他重要性采样函数的自适应粒子数方案（如以样本分布质量为依据或设置其他特殊的阈值的方法），并和本文中给出的基于 KL 距离采样的 KLD-PP-PF-TBD 方法进行比较。

（2）研究基于自适应粒子数的粒子滤波算法在工程应用中的实时性问题。本文对无源声呐实测数据的处理是离线进行的，但在一些实时处理应用场景中，传感器输出的数据率可能高于粒子滤波器的数据更新率，此时即需要在采样粒子数 and 数据处理能力之间做合适的权衡，引入类似于本文提出的自适应粒子数策略将有助于解决该类问题。

（3）研究粒子滤波在硬件平台上的并行计算方法，例如开发基于 CUDA 的 GPU 或者基于 FPGA 等平台上的粒子滤波算法高效实现方法。粒子滤波算法中，采样与权重递归更新的特性非常适合并行处理，而并行处理的主要困难在于重采样过程。随着硬件平台在计算和存储能力上的快速发展，研究粒子滤波算法的高效硬件实现方案有助于进一步挖掘粒子滤波算法的工程应用潜力。

（4）本文在无源声呐实测数据上对多目标 PF-TBD 的实现方案进行了初步研究，除此之外还可以将本文工作应用于多目标非线性检测跟踪的其它工程领域，如研究 PF-TBD 在如雷达、红外或视频图像等其它体制检测跟踪系统中的具体工程实现方案。

致 谢

从二零一二年秋天踏入小雨中的清水河校园，算到今日，在成电学习生活了已近七年。在成电生活的尾声中，想对七年之间所有陪伴并帮助我的师长、同学、朋友和家人，由衷地说一声“谢谢”。

感谢导师易伟副教授三年来给予作者的帮助。易老师对课题的深入见解，使我得以一窥跟踪领域的前沿知识；更是易老师三年来不断的激励和指引，让我能更加坦然地直面自身的缺点与问题，勇敢地展示工作中的疑惑与错误，并积极寻求帮助，从而更自信地去解决学习和生活中的困难。同时也要感谢教研室团队的孔令讲老师、崔国龙老师和张天贤老师营造了良好的教研室工作氛围，让我们在步入社会前得到了极大的锻炼。

在教研室的学习也让我深刻体认了这样的道理：推进工作的最好办法就是立刻投入具体实验操作中，而非浮于顶层的计划和理论陷入“空转”；如同本文基于KLD采样的粒子滤波算法一样，最终的采样粒子数量并非是在开始采样操作前就能算出来的，而是通过逐个的粒子采样的不断迭代，最后这个采样停止的阈值才自然而然地出现在面前。

感谢教研室的杨东超师兄、徐璐霄师兄、黎明师兄、付玲枝师妹等在课题上对我的巨大帮助。感谢文鸣、汪子钦、孟令同、陈国浩、曹凌霄、赵青松、陈芳香、王亚茹、肖新剑、翟博文、黄大通、黄华宾、曾冬冬、袁野、时巧、葛萌萌等诸位同窗在三年生活中的共同陪伴。特别感谢文鸣在求职和论文撰写期间对我的帮助。你们让我明白了没有人是一座孤岛，在学习生活中，与师长和同侪敞开心扉的交流才是个体迅速成长的捷径，一个人闭门造车难以出门合辙。感谢你们为教研室营造了极佳的学习氛围，也让这里成为一个从不缺少欢声笑语的集体。感谢本科期间鄢振宇、王凯、都晟华、喻根、耿昊晟等好友，虽然你们已天各一方，但仍能时常鼓舞我向你们努力看齐，不负你们的期许；感谢游泳队的博士生龙腾、卓中流师兄、李优优、马叶子师姐以及一同征战全国赛的孙佳明和徐煜伟等队友，与你们的幸运相识，使我在成电的生活永不孤单，希望四十年后还能与你们继续这段水中奇缘。

七年之间，深深感愧张晏京叔叔在课外自本科至今对我无私的孜孜教诲，尤其是在我屡屡犯错后依旧耐心帮助我改造自己的缺点，您高标准的工作准则、学习方法论和生活态度是我在今后人生中要不懈学习的课题。

最后，我还要特别感谢我的父亲和母亲，你们对我二十五年如一日的养育、教诲、关心和支持是使我能够走到今天的最大动力。

参考文献

- [1] M. S. Arulampalam, S. Maskell, N. Gordon, et al. A tutorial on particle filters for online nonlinear/non-Gaussian Bayesian tracking[J]. Signal Processing, IEEE Transactions, 2002 , 50(2): 174-188.
- [2] M. Hadzagic, H. Michalska, E. Lefebvre. Track-before-detect methods in tracking low-observable targets: a survey[J]. Sensors & Transducers Magazine (S&Te-Digest), Special Issue, 2005, (8): 374-380.
- [3] C. Kreucher, K. Kastella, A. O. Hero. Multitarget tracking using the joint multitarget probability density[J]. IEEE Transactions on Aerospace and Electronic Systems, 2005, 41(4): 1396-1414.
- [4] I. S. Reed, R. M. Gagliardi, L. B. Stotts. Optical moving target detection with 3-D matched filtering[J]. IEEE Transactions on Aerospace and Electronic Systems, 1988, 24(4): 327-336.
- [5] S. D. Blostein, T. S. Huang. Detecting small, moving objects in image sequences using sequential hypothesis testing[J]. IEEE Transactions on Signal Processing, 1991, 39(7): 1611-1629.
- [6] B. Fardi, G. Wanielik. Hough transformation based approach for road border detection in infrared images[C]. IEEE Intelligent Vehicles Symposium, 2004. IEEE, 2004: 549-554.
- [7] W. Yi, L. Kong, J. Yang. Thresholding process based dynamic programming track-before-detect algorithm[J]. IEICE transactions on communications, 2013, 96(1): 291-300.
- [8] E. Grossi, M. Lops, L. Venturino. A track-before-detect algorithm for the detection of a Markov target in the presence of missing observations[C]. 2013 IEEE International Conference on Acoustics, Speech and Signal Processing. IEEE, 2013: 6382-6386.
- [9] Y. Boers, H. Driessen. Particle filter-based track before detect algorithms[C]. Signal and Data Processing of Small Targets 2003. International Society for Optics and Photonics, 2004, 5204: 20-31.
- [10] N. J. Gordon, D. J. Salmond, A. F. M. Smith. Novel approach to nonlinear/non-Gaussian Bayesian state estimation[C]. IEE Proceedings F (Radar and Signal Processing). IET Digital Library, 1993, 140(2): 107-113.
- [11] J. Carpenter, P. Clifford, P. Fearnhead. Improved particle filter for nonlinear problems[J]. IEE Proceedings-Radar, Sonar and Navigation, 1999, 146(1): 2-7.
- [12] D. J. Salmond, H. Birch. A particle filter for track-before-detect[C]. Proceedings of the 2001 American Control Conference.(Cat. No. 01CH37148). IEEE, 2001, 5: 3755-3760.

- [13] M. Rollason, D. Salmond. A particle filter for track-before-detect of a target with unknown amplitude[C]. IEE Target Tracking: Algorithms and Applications (Ref. No. 2001/174). IET, 2001: 14/1-14/4 vol. 1.
- [14] M. G. Rutten, N. J. Gordon, S. Maskell. Particle-based track-before-detect in Rayleigh noise[C]. Signal and Data Processing of Small Targets, 2004. International Society for Optics and Photonics, 2004, 5428: 509-520.
- [15] M. G. Rutten, N. J. Gordon, S. Maskell. Recursive track-before-detect with target amplitude fluctuations[J]. IEE Proceedings-Radar, Sonar and Navigation, 2005, 152(5): 345-352.
- [16] M. G. Rutten, B. Ristic, N. J. Gordon. A comparison of particle filters for recursive track-before-detect[C]. 2005 7th International Conference on Information Fusion. IEEE, 2005, 1: 7 pp.
- [17] 李天成, 范红旗, 孙树栋. 粒子滤波理论, 方法及其在多目标跟踪中的应用[J]. 自动化学报, 2015, 41(12): 1981-2002.
- [18] O. Straka, M. Šimandl. A survey of sample size adaptation techniques for particle filters[J]. IFAC Proceedings Volumes, 2009, 42(10): 1358-1363.
- [19] D. Fox. Adapting the sample size in particle filters through KLD-sampling[J]. The international Journal of robotics research, 2003, 22(12): 985-1003.
- [20] D. Fox, W. Burgard, F. Dellaert, et al. Monte Carlo localization: Efficient position estimation for mobile robots[J]. AAAI/IAAI, 1999, 1999(343-349): 2-2.
- [21] D. Fox. KLD-sampling: Adaptive particle filters[C]. Advances in neural information processing systems. 2002: 713-720.
- [22] O. Straka, M. Šimandl. Sample size adaptation for particle filters[J]. IFAC Proceedings Volumes, 2004, 37(6): 437-442.
- [23] V. Elvira, J. Míguez and P. M. Djurić, "Adapting the Number of Particles in Sequential Monte Carlo Methods Through an Online Scheme for Convergence Assessment," in IEEE Transactions on Signal Processing, vol. 65, no. 7, pp. 1781-1794, 1 April, 2017.
- [24] Y. Boers, J. N. Driessen, F. Verschure, et al. A multi target track before detect application[C]. 2003 Conference on Computer Vision and Pattern Recognition Workshop. IEEE, 2003, 9: 104-104.
- [25] M. Orton, W. Fitzgerald. A Bayesian approach to tracking multiple targets using sensor arrays and particle filters[J]. IEEE Transactions on Signal Processing, 2002, 50(2): 216-223.
- [26] C. M. Kreucher, K. D. Kastella, A. O. Hero. Tracking multiple targets using a particle filter representation of the joint multitarget probability density[C]. Signal and Data Processing of Small Targets 2003. International Society for Optics and Photonics, 2004, 5204: 258-270.

- [27] A. Doucet, S. Godsill, C. Andrieu. On sequential Monte Carlo sampling methods for Bayesian filtering[J]. Statistics and computing, 2000, 10(3): 197-208.
- [28] M. R. Morelande, C. M. Kreucher, K. Kastella. A Bayesian approach to multiple target detection and tracking[J]. IEEE Transactions on Signal Processing, 2007, 55(5): 1589-1604.
- [29] B. M. Turner, T. Van Zandt. A tutorial on approximate Bayesian computation[J]. Journal of Mathematical Psychology, 2012, 56(2): 69-85.
- [30] A. F. Garcia-Fernandez, J. Grajal, M. R. Morelande. Two-layer particle filter for multiple target detection and tracking[J]. IEEE Transactions on Aerospace and Electronic Systems, 2013, 49(3): 1569-1588.
- [31] Á. F. García-Fernández, J. Grajal. Multitarget tracking using the joint multitrack probability density[C]. 2009 12th International Conference on Information Fusion. IEEE, 2009: 595-602.
- [32] 龚亚信,杨宏文,胡卫东,等.基于多模粒子滤波的机动弱目标检测前跟踪[J].电子与信息学报, 2008, 4(30): 941-944.
- [33] W. Yi, M. R. Morelande, L. J. Kong, et al. An efficient particle filter for multi-target tracking using an independence assumption[C]. 2012 15th International Conference on Information Fusion. IEEE, 2012: 2378-2385.
- [34] 易伟. 基于检测前跟踪技术的多目标跟踪算法研究[D].成都:电子科技大学, 2012, 46-68.
- [35] A. Alin, M. V. Butz, J. Fritsch. Tracking moving vehicles using an advanced grid-based Bayesian filter approach[C]. 2011 IEEE Intelligent Vehicles Symposium (IV). IEEE, 2011: 466-472.
- [36] L. Ljung. Asymptotic behavior of the extended Kalman filter as a parameter estimator for linear systems[J]. IEEE Transactions on Automatic Control, 1979, 24(1): 36-50.
- [37] O. Cappé, S. J. Godsill, E. Moulines. An overview of existing methods and recent advances in sequential Monte Carlo[J]. Proceedings of the IEEE, 2007, 95(5): 899-924.
- [38] N. J. Gordon, D. J. Salmond, A. F. M. Smith Novel approach to nonlinear/non-Gaussian Bayesian state estimation[C]. IEE Proceedings F (Radar and Signal Processing). IET Digital Library, 1993, 140(2): 107-113.
- [39] J. D. Hol, T. B. Schon, F. Gustafsson. On resampling algorithms for particle filters[C]. 2006 IEEE nonlinear statistical signal processing workshop. IEEE, 2006: 79-82.
- [40] R. Douc, O. Cappé. Comparison of resampling schemes for particle filtering[C]. ISPA 2005. Proceedings of the 4th International Symposium on Image and Signal Processing and Analysis, 2005. IEEE, 2005: 64-69.
- [41] T. Li, M. Bolic, P. M. Djuric. Resampling methods for particle filtering: classification, implementation, and strategies[J]. IEEE Signal Processing Magazine, 2015, 32(3): 70-86.

- [42] M. K. Pitt, N. Shephard. Filtering via simulation: Auxiliary particle filters[J]. Journal of the American statistical association, 1999, 94(446): 590-599.
- [43] M. Lin, R. Chen, J. S. Liu. Lookahead strategies for sequential Monte Carlo[J]. Statistical Science, 2013, 28(1): 69-94.
- [44] X. Wang, R. Chen, D. Guo. Delayed-pilot sampling for mixture Kalman filter with application in fading channels[J]. IEEE Transactions on Signal Processing, 2002, 50(2): 241-254.
- [45] N. L. Johnson, S. Kotz, N. Balakrishnan. Continuous univariate distributions, Vol. 1, 2nd Edition[M]. Wiley, 1994, 481-520.
- [46] I. Csiszár, P. C. Shields. Information theory and statistics: A tutorial[J]. Foundations and Trends in Communications and Information Theory, 2004, 1(4): 417-528.
- [47] X. Li, Y. Wang, Z. Wang, et al. Effect of Errors in Beamforming Analysis Applied for MVDR and CBF Method[J]. The Open Electrical & Electronic Engineering Journal, 2016, 10(1).
- [48] S. Stergiopoulos. Advanced beamformers[M]. Advanced Signal Processing. CRC Press, 2009, 99-166.
- [49] 方世良,杜栓平,罗昕炜,等.水声目标特征分析与识别技术[J].中国科学院院刊, 2019, 34(03): 297-305.
- [50] 何子述.现代数字信号处理及其应用[M].北京:清华大学出版社, 2009, 287-339.
- [51] R. Schmidt. Multiple emitter location and signal parameter estimation[J]. IEEE transactions on antennas and propagation, 1986, 34(3): 276-280.
- [52] 李启虎,潘学宝,尹力.数字式声呐中一种新的背景均衡算法[J].声学学报, 2000, 25(1): 5-9.
- [53] 芦俊,张颜岭,张凤园.一种被动声呐线谱背景均衡算法[J].声学与电子工程, 2016(03): 20-22.
- [54] L. Xu, C. Liu, W. Yi, et al. A particle filter based track-before-detect procedure for towed passive array sonar system[C]. 2017 IEEE Radar Conference (RadarConf). IEEE, 2017: 1460-1465.
- [55] 徐璐霄.基于被动阵列的水声弱目标检测前跟踪算法研究[D].成都:电子科技大学, 2018, 47-68.

攻读硕士学位期间取得的科研成果